



PROPOSAL DISERTASI

Pengembangan Sistem Prediksi Gempa Bumi Komprehensif Berbasis Prekursor Geomagnetik Menggunakan Model Hybrid Deep Learning

Sumawan
NRP.7009232004

DOSEN PEMBIMBING
Dr. Bambang Lelono Widjiantoro, S.T., M.T.
Prof. Dr. Katherin Indriawati, S.T, M.T.
Dr. Muhamad Syirojudin, M.Si.

PROGRAM DOKTOR
DEPARTEMEN TEKNIK FISIKA
FAKULTAS TEKNOLOGI INDUSTRI DAN REKAYASA SISTEM
INSTITUT TEKNOLOGI SEPULUH NOPEMBER SURABAYA
SURABAYA

(Halaman ini sengaja dikosongkan)

**LEMBAR PENGESAHAN
PROPOSAL DISERTASI**

Judul : Pengembangan Sistem Prediksi Gempa Bumi Komprehensif
Berbasis Prekursor Geomagnetik Menggunakan Model Hybrid
Deep Learning

Oleh : Sumawan, ST, MM

NRP. : 7009232004

Telah diseminarkan pada:

Hari : Rabu

Tanggal : 23 April 2025

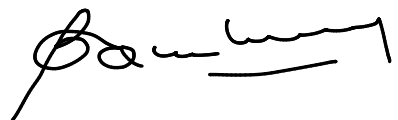
Tempat : Ruang Social Space Departemen Teknik Fisika ITS Surabaya

Mengetahui / menyetujui:

Dosen Penguji:


Calon Dosen Pembimbing:

1. Dr. Detak Yan Pratama, S.T., M.Sc.
NIP 198401012012121002


1. Dr. Bambang L. Widjiantoro, S.T., M.T
NIP 196905071995121001

2. Dr. Ir. Dwa D. Warnana S.Si., M.Si
NIP 197601232000031001


2. Prof. Dr. Katherin Indriawati, S.T, M.T
NIP 197605232000122001


3. Dr. Muhamad Syirojudin, M.Si
NIP 198508092008011006

(Halaman ini sengaja dikosongkan)

PENGEMBANGAN SISTEM PREDIKSI GEMPABUMI KOMPREHENSIF BERBASIS PREKUSOR GEOMAGNETIK MENGGUNAKAN MODEL HYBRID DEEP LEARNING

Nama Mahasiswa : Sumawan
NRP : 7009232004
Pembimbing : Dr. Bambang Lelono Widjiantoro, S.T., M.T.
Prof. Dr. Katherin Indriawati, S.T, M.T.
Dr. Muhamad Syirojudin, M.Si

ABSTRAK

Prediksi gempa bumi merupakan tantangan besar dalam upaya mitigasi bencana yang berdampak pada keselamatan manusia dan infrastruktur. Studi menunjukkan bahwa sinyal prekursor pada rekaman medan geomagnetik, seperti perubahan rasio Z/H, dapat muncul 7–11 hari sebelum gempa terjadi. Namun, keterbatasan dataset historis dan inkonsistensi dalam mendeteksi sinyal ini menghambat pengembangan sistem prediksi yang andal.

Tujuan penelitian ini adalah mengembangkan sistem prediksi gempabumi yang komprehensif berbasis prekursor geomagnetik, dengan mengintegrasikan data multi-parameter melalui model hybrid deep learning. Pada tahun pertama, penelitian akan difokuskan pada deteksi sinyal prekursor dengan mengumpulkan dan memproses data geomagnetik (komponen H, D, dan Z) selama minimal 5 tahun dari jaringan stasiun BMKG. Data tersebut akan diproses (pembersihan, normalisasi, pelabelan) dan fitur-fitur penting akan diekstraksi menggunakan teknik Wavelet Scattering Transform (WST) dan analisis rasio Z/H. Model deteksi akan dikembangkan dengan menggunakan Convolutional Neural Network (CNN) yang dilengkapi dengan fitur self-updating agar dapat beradaptasi dengan kondisi seismotektonik lokal. Selain itu, generator data sintetis akan dikembangkan untuk augmentasi dataset. Pada tahun kedua, hasil deteksi prekursor tersebut akan diintegrasikan dengan data pendukung lainnya, seperti data seismik, ionosferik, dan geoatmosferik.

Integrasi dilakukan melalui fusi data level fitur dengan teknik Principal Component Analysis (PCA) untuk menyusun vektor fitur yang lengkap. Model hybrid deep learning, yang menggabungkan CNN untuk ekstraksi fitur spasial dan Recurrent Neural Network (RNN) untuk analisis temporal, akan dikembangkan guna mengestimasi parameter gempa seperti magnitudo, lokasi, dan waktu kejadian. Luaran yang ditargetkan meliputi sistem prediksi gempa real-time dengan akurasi tinggi, dashboard peringatan dini, serta publikasi ilmiah yang mendemonstrasikan peningkatan kinerja prediksi gempa berbasis integrasi multi-parameter..

Kata Kunci : Prediksi gempa; sinyal precursor; data geomagnetic; hybrid deep learning; integrasi multi-parameter.

DAFTAR ISI

Lembar Pengesahan	iii
Abstrak	v
Daftar isi	vii
Daftar gambar	ix
Daftar tabel	xi
Bab 1 Pendahuluan	1
1.1. Latar Belakang	1
1.2. Perumusan Masalah	8
1.3. Tujuan Penelitian	8
1.4. Manfaat Penelitian	9
1.5. Batasan Penelitian	9
1.6. Kebaharuan Penelitian	10
1.7. State of the Art	10
Bab 2 Tinjauan Pustaka	13
2.1. Penelitian Terdahulu	13
2.1.1. Hubungan Antar Pustaka	32
2.1.2. Peta Jalan Penelitian	32
2.2. Dasar Teori	33
2.2.1. Teori Gempa Bumi	33
2.2.2. Data Ultra Low Frequency Magnet Bumi	35
2.2.3. Fisis Sumber Emisi Seismo-Electromagnetik (SEM)	38
2.2.4. Stasiun Pencatat Data Magnet Bumi	40
2.2.5. Metode Prekursor Gempa Bumi	41
2.2.6. Prosesing Sinyal Untuk Penentuan Onset Time	42
2.2.7. Penentuan Azimuth Anomali	46
2.2.8. Penentuan Magnitude	47
2.2.9. Convolutional Neural Network	49
Bab 3 Metodologi Penelitian	55
3.1. Pengumpulan dan Persiapan Data Pendukung	55
3.2. Ekstraksi Fitur	56
3.3. Pembuatan Model Deteksi Menggunakan CNN	60
3.4. Pembuatan Data Augmentasi	63
3.5. Pengembangan Model CNN Fitur Self-Updating	60
3.6. Integrasi Data Multi-Parameter	66
3.7. Pengembangan Model Prediksi Parameter Gempa	68
3.8. Pengembangan Generator Data Sintesis	69
3.9. Pengembangan Model Prediksi Fitur Online Learning	70
3.10. Jadwal Pelaksanaan Penelitian	70
Daftar Pustaka	73

(Halaman ini sengaja dikosongkan)

DAFTAR GAMBAR

Gambar 1.1 Peta Gempabumi Merusak dan Tsunami di Indonesia.....	2
Gambar 1.2 Peta Jalan Penelitian.....	12
Gambar 2.1 Diagaram hubungan antar pustaka	32
Gambar 2.2 Peta Tektonik Wilayah Indonesia (Pusat Studi Gempa Nasional (Indonesia) & Pusat Penelitian dan Pengembangan Perumahan dan Permukiman (Indonesia), 2017)	35
Gambar 2.3 Spektrum Frekuensi gelombang elektromagnetik (US Department of Commerce, 2003)	36
Gambar 2.4 Mekanisme fisis emisi ULF di sekitar lokasi sumber gempabumi (Hattori dkk., 2006)	39
Gambar 2.5 Peta Sensor Magnet Bumi Untuk Prekursor BMKG	40
Gambar 2.6 Korelasi antara gelombang elektromagnetik dan gelombang seismik (Karakelian et al., 2000)	42
Gambar 2.7 Raw Data Harian Magnet Bumi	43
Gambar 2.8 Hasil Koreksi Raw Data Magnet Bumi.....	44
Gambar 2.9 Hasil Pengolahan ULF Magnet Bumi Pc3	45
Gambar 2.10 Hasil Pengolahan ULF Magnet Bumi Pc3	45
Gambar 2.11 Grafik koefisien determinasi, koefisien korelasi, dan standar deviasi(1)	48
Gambar 2.12 Grafik koefisien determinasi, koefisien korelasi, dan standar deviasi(2)	49
Gambar 2.13 Diagram skema arsitektur jaringan saraf konvolusional (CNN).51	
Gambar 2.14 Diagram analisis maju dan propagasi mundur.	52
Gambar 3.1 Diagram Alir Penelitian	56
Gambar 3.2. Spektogram ULF data magnet PC 3 (a) dan PC 4 (b), pada komponen Z stasiun LIWA	57
Gambar 3.3 Diagram Arsitektur Convolutional Neural Network	61

(Halaman ini sengaja dikosongkan)

DAFTAR TABEL

Tabel 2.1 Rangkuman Referensi Yang Digunakan.....	14
Tabel 2.2 Klasifikasi Pc dan Pi Propagasi Gelombang ULF.....	36
Tabel 3.1 Jadwal Pelaksanaan Penelitian.....	681

BAB 1

PENDAHULUAN

1.1. Latar Belakang

Gempa bumi merupakan fenomena alam yang kompleks dan memiliki potensi dampak merusak yang sangat besar terhadap kehidupan manusia. Indonesia merupakan negara yang terletak di antara 3 lempeng tektonik dunia yaitu Lempeng Esurasia, Lempeng Australia dan Lempeng Pasifik dengan kejadian gempabumi dan tsunami yang tinggi akibatnya terdapat kurban jiwa yang sangat besar. Badan Nasional Penanggulangan Bencana (BNPB) mencatat telah terjadi 781(tujuh ratus delapan puluh satu) kejadian bencana gempabumi yang mengakibatkan korban jiwa sebanyak 16.500 (enam belas ribu lima ratus) orang meninggal, 1.541(seribu lima ratus empat puluh satu) orang hilang dan 28 (dua puluh delapan) kejadian bencana gempabumi yang menimbulkan tsunami mengakibatkan korban jiwa sebanyak 5.064 (lima ribu enam puluh empat) orang meninggal, 3.062 (tiga ribu enam puluh dua) orang hilang (Data Informasi Bencana Indonesia (DIBI) Badan Nasional Penanggulangan Bencana Republik Indonesia, n.d.).

Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) sebagai lembaga pemerintah yang berwenang dalam pendeteksian gempabumi dan tsunami, telah mengoperasikan lebih dari 530 (lima ratus tiga puluh) unit seismograph digital di seluruh Wilayah Indonesia (Media, 2024). Seismograph sebagai peralatan pengukur aktivitas seismik bekerja sesaat setelah kejadian gempabumi. Tingginya aktivitas gempabumi dilaporkan sebanyak 10.789 kali dalam berbagai magnitudo dan kedalaman selama 2023 di Indonesia (EQ Repository | BMKG, n.d.). Gambar 1.1. adalah peta gempa bumi merusak periode 1923 sampai dengan Juni 2022 (Badan Meteorologi, Klimatologi, dan Geofisika, 2024). Pada gambar tersebut dapat dilihat bahwa hamper seluruh wilayah Indonesia mempunyai sejarah gempa bumi merusak dan berpotensi terulang di waktu yang akan datang. Hal ini menggambarkan potensi gempa bumi merusak di seluruh Indonesia sangat tinggi dan ancaman bencana gempa bumi sangat nyata bagi pembangunan.

magnet bumi sebagai indikator awal sebelum terjadinya gempa bumi. Pada tahun 2017, BMKG telah memasang peralatan magnet bumi di 17 lokasi di Indonesia untuk memantau prekursor gempa bumi. Jumlah ini tidak sebanyak seismograf yang dioperasikan oleh BMKG. Hal ini disebabkan alat ukur geomagnetik—seperti fluxgate magnetometer yang memiliki tingkat sensitivitas tinggi untuk mendeteksi variasi medan magnet—biasanya memerlukan investasi yang lebih besar. Dengan kemajuan teknologi dan penelitian geofisika, banyak dikembangkan model prekursor gempabumi dengan menggunakan data magnet bumi. Data variasi magnet bumi banyak diteliti sebagai precursor gempa bumi.

Data geomagnetik BMKG dianalisis untuk mendeteksi tanda-tanda awal gempa bumi yang mungkin terjadi. Dalam hal ini, sistem deteksi prekursor dilakukan dengan menganalisis rasio perbandingan antara komponen vertikal (Z) dan komponen horizontal (H) dari sinyal magnet bumi. Teknik ini dikenal sebagai analisis rasio daya polarisasi Z/H , dimana perubahan signifikan pada nilai rasio ini—misalnya peningkatan nilai Z/H —dapat mengindikasikan adanya anomali pada sinyal geomagnetik ultra-low frequency (ULF) yang seringkali muncul beberapa hari hingga minggu sebelum terjadinya gempa bumi. Teknik tersebut telah diaplikasikan dalam penelitian dan pengamatan oleh BMKG, khususnya untuk memantau aktivitas seismik dengan mengidentifikasi onset (tanda awal) anomali geomagnetik yang berpotensi menjadi prekursor gempa (Ahadi et al., 2014a; Ahyar & Sunardi, 2017). Metode ini dilaporkan mampu mengidentifikasi anomali geomagnetik yang muncul sekitar 7 hingga 11 hari sebelum terjadinya gempa dengan tingkat keberhasilan (hit rate) berada di kisaran 70% hingga 80%. Namun nilai akurasi ini dapat bervariasi tergantung pada lokasi pengamatan, kualitas data, dan kondisi geomagnetik. Selain itu, hingga kini belum ada sistem prediksi gempa yang komprehensif yang mampu mengintegrasikan seluruh parameter penting—seperti estimasi magnitudo, lokasi, dan waktu kejadian gempa—untuk menghasilkan peringatan dini yang lebih akurat dan operasional.

Penelitian-penelitian terdahulu, seperti yang dilakukan oleh Yumoto (1986), memberikan dasar yang kuat dalam memahami mekanisme generasi dan propagasi pulsasi magnetik di wilayah lintang rendah. Pengetahuan ini penting untuk mengembangkan model prediksi yang lebih akurat dan dapat diandalkan. Di sisi

lain, penelitian Hayakawa et al. (2000) di Biak, Indonesia, menunjukkan adanya precursor elektromagnetik ULF yang signifikan sebelum terjadinya gempa bumi, yang dapat menjadi bukti tambahan untuk validitas metode ini. Karya Hayakawa et al. (2000) di Biak, Indonesia, dan studi lanjutan oleh Hayakawa et al. (2007) memberikan bukti lebih lanjut tentang peran emisi ULF sebagai precursor gempa bumi. Temuan-temuan ini menunjukkan bahwa variasi geomagnetik ULF dapat menjadi indikator yang dapat diandalkan untuk aktivitas seismik yang akan datang. Hayakawa (2016) juga menegaskan pentingnya fenomena elektromagnetik dalam konteks prediksi gempa bumi, memperkenalkan metode baru yang dapat digunakan untuk mendeteksi tanda-tanda awal gempa bumi.

Salah satu studi penting oleh Hamidi et al. (2024) menunjukkan korelasi antara emisi frekuensi ultra-rendah magnet bumi dan gempa bumi, serta memberikan indikator yang kuat terkait aktivitas seismik di Sumatera. Penelitian oleh Marzuki et al. (2022) juga memberikan wawasan berharga dengan mendokumentasikan anomali geomagnetik ULF yang berhubungan dengan swarm gempa bumi di Kepulauan Pagai, Sumatera. Temuan ini memperkuat hipotesis bahwa sinyal ULF dapat berfungsi sebagai precursor gempa bumi yang efektif. Lebih lanjut, penelitian Hattori et al. (2006) menggunakan analisis spektral singular dan analisis komponen utama untuk mendiskriminasi sinyal ULF terkait gempabumi. Metode ini menawarkan cara yang lebih rinci untuk mengekstrak informasi dari data geomagnetik, yang berpotensi meningkatkan resolusi temporal dan spasial prediksi.

Perkembangan dalam bidang pembelajaran mesin memberikan kontribusi signifikan terhadap penelitian prediksi gempa bumi. Petrescu dan Moldovan (2022) mengusulkan model neural network untuk mendeteksi sinyal precursory gempa bumi dalam catatan medan geomagnetik. Pendekatan ini dapat mengidentifikasi pola anomali yang tidak mudah terlihat melalui metode konvensional, dengan meningkatkan presisi deteksi anomali geomagnetik. Pappoe et al. (2023) memperkenalkan kombinasi pendekatan machine learning dengan analisis wavelet untuk deteksi otomatis pulsasi geomagnetik Pc5. Hasil penelitian ini menunjukkan potensi besar dalam meningkatkan efisiensi dan akurasi deteksi precursor gempa

bumi. Model ini memungkinkan identifikasi yang lebih cepat dan andal terhadap pola anomali geomagnetik yang terkait dengan aktivitas seismik.

Data historis penelitian sebelumnya menunjukkan potensi sinyal peringatan dini, namun masih ada tantangan dalam memastikan konsistensi dan keandalan temuan tersebut. Sebagai contoh, Petrescu dan Moldovan (2022) menggunakan model neural network untuk deteksi sinyal *precursory* yang dapat meningkatkan presisi prediksi, tetapi tidak membuat prediksi magnitude dan lokasi gempa bumi, dan masih diperlukan penelitian lebih lanjut untuk validasi metode ini. Pada penelitian Pappoe et al. (2023), sudah mencoba yang menggabungkan pendekatan *machine learning* dengan analisis *wavelet* namun juga belum membuat prediksi parameter gempa bumi. Hamidi et al. (2024) dengan menggunakan data magnet bumi di wilayah Pulau Sumatera menunjukkan hasil prekursor gempa bumi beserta parameternya dengan metode perbandingan komponen Z/H. Solusi umum yang diusulkan dengan pengembangan dan integrasi teknik analisis data lanjutan, seperti pembelajaran mesin dengan data training hasil analisis rasio komponen Z/H, yang dapat meningkatkan kemampuan dalam mendeteksi dan menganalisis anomali geomagnetik ULF. Hamidi dengan perbandingan komponen Z/H akan mencapai akurasi yang statis karena metode ini tidak dinamis meski semakin banyak kejadian gempa bumi yang valid diprediksi.

Meskipun teknologi deteksi gempabumi telah berkembang pesat, namun memprediksi waktu dan lokasi terjadinya gempa dengan tingkat akurasi yang tinggi masih menjadi tantangan besar dalam dunia ilmu kebumihan. Banyak penelitian yang menggarisbawahi potensi anomali geomagnetik ULF sebagai prekursor gempa bumi, namun masih ada beberapa kesenjangan penelitian yang perlu diisi. Beberapa kesenjangan penelitian diantaranya kebutuhan untuk validasi lebih lanjut dari temuan-temuan ini di berbagai wilayah seismik Indonesia dengan karakteristik geologis yang berbeda, frekuensi dominan yang emisi ULF di Indonesia dan juga tingkat akurasi prekursor. Sistem prekursor gempa bumi data magnet bumi BMKG saat ini, menggunakan pendekatan statistic dan matematik berupa analisis rasio perbandingan Z/H yang menghasilkan akurasi di bawah 70%.

Masalah utama yang diangkat dalam penelitian ini adalah untuk meningkatkan akurasi prekursor gempabumi data magnet dengan mengaplikasikan *Convolutional*

Neural Network (CNN) dan Random Forest (RF). Penelitian ini diharapkan menghasilkan peningkatan akurasi prekursor terhadap parameter gempabumi, yaitu magnitudo dan lokasi gempabumi hasil prediksi model deep learning. Masalah utama dalam penelitian ini adalah untuk meningkatkan akurasi prekursor gempa bumi data magnet bumi dengan mengaplikasikan deep learning. Tingkat akurasi yang diharapkan berdasarkan parameter gempa bumi, yaitu magnitudo dan lokasi gempa bumi hasil prediksi model deep learning. Data historis penelitian sebelumnya menunjukkan potensi sinyal peringatan dini, namun masih ada tantangan dalam memastikan konsistensi dan keandalan temuan tersebut. Sebagai contoh, Petrescu dan Moldovan (2022) menggunakan model neural network untuk deteksi sinyal precursory yang dapat meningkatkan presisi prediksi, tetapi tidak membuat prediksi magnitudo dan lokasi gempa bumi, masih diperlukan penelitian lebih lanjut untuk validasi metode ini. Pada penelitian Pappoe et al. (2023), sudah mencoba yang menggabungkan pendekatan machine learning dengan analisis wavelet namun juga belum membuat prediksi parameter gempa bumi. Hamidi et al. (2024) dengan menggunakan data magnet bumi di wilayah Pulau Sumatera menunjukkan hasil prekursor gempa bumi beserta parameternya dengan metode perbandingan komponen Z/H. Solusi umum yang diusulkan dengan pengembangan dan integrasi teknik analisis data lanjutan, seperti pembelajaran mesin dengan data training hasil analisis rasio komponen Z/H, yang dapat meningkatkan kemampuan dalam mendeteksi dan menganalisis anomali geomagnetik ULF.

Upaya untuk meningkatkan akurasi prediksi gempa bumi melalui analisis anomali geomagnetik ULF telah menghasilkan sejumlah solusi inovatif yang diangkat dalam berbagai literatur ilmiah. Salah satu studi penting oleh Hamidi et al. (2024) menunjukkan korelasi antara emisi frekuensi ultra-rendah magnet bumi dan gempa bumi, serta memberikan indikator yang kuat terkait aktivitas seismik di Sumatera. Integrasi parameter geofisika ini menawarkan pendekatan multidisipliner yang dapat meningkatkan keandalan prediksi gempa bumi, dengan memanfaatkan variasi data yang komprehensif untuk mengidentifikasi tanda-tanda awal gempa bumi. Penelitian oleh Marzuki et al. (2022) juga memberikan wawasan berharga dengan mendokumentasikan anomali geomagnetik ULF yang berhubungan dengan swarm gempa bumi di Kepulauan Pagai, Sumatera. Temuan

ini memperkuat hipotesis bahwa sinyal ULF dapat berfungsi sebagai precursor gempa bumi yang efektif. Lebih lanjut, penelitian Hattori et al. (2006) menggunakan analisis spektral singular dan analisis komponen utama untuk mendiskriminasi sinyal ULF terkait gempa bumi. Metode ini menawarkan cara yang lebih rinci untuk mengekstrak informasi dari data geomagnetik, yang berpotensi meningkatkan resolusi temporal dan spasial prediksi. Penelitian-penelitian terdahulu, seperti yang dilakukan oleh Yumoto (1986), memberikan dasar yang kuat dalam memahami mekanisme generasi dan propagasi pulsasi magnetik di wilayah lintang rendah. Pengetahuan ini penting untuk mengembangkan model prediksi yang lebih akurat dan dapat diandalkan. Di sisi lain, penelitian Hayakawa et al. (2000) di Biak, Indonesia, menunjukkan adanya precursor elektromagnetik ULF yang signifikan sebelum terjadinya gempa bumi, yang dapat menjadi bukti tambahan untuk validitas metode ini. Karya Hayakawa et al. (2000) di Biak, Indonesia, dan studi lanjutan oleh Hayakawa et al. (2007) memberikan bukti lebih lanjut tentang peran emisi ULF sebagai precursor gempa bumi. Temuan-temuan ini menunjukkan bahwa variasi geomagnetik ULF dapat menjadi indikator yang dapat diandalkan untuk aktivitas seismik yang akan datang. Hayakawa (2016) juga menegaskan pentingnya fenomena elektromagnetik dalam konteks prediksi gempa bumi, memperkenalkan metode baru yang dapat digunakan untuk mendeteksi tanda-tanda awal gempa bumi.

Selain itu, perkembangan dalam bidang pembelajaran mesin memberikan kontribusi signifikan terhadap penelitian prediksi gempa bumi. Petrescu dan Moldovan (2022) mengusulkan model neural network untuk mendeteksi sinyal precursory gempa bumi dalam catatan medan geomagnetik. Pendekatan ini dapat mengidentifikasi pola anomali yang tidak mudah terlihat melalui metode konvensional, dengan meningkatkan presisi deteksi anomali geomagnetik. Pappoe et al. (2023) memperkenalkan kombinasi pendekatan machine learning dengan analisis wavelet untuk deteksi otomatis pulsasi geomagnetik Pc5. Hasil penelitian ini menunjukkan potensi besar dalam meningkatkan efisiensi dan akurasi deteksi

precursor gempa bumi. Model ini memungkinkan identifikasi yang lebih cepat dan andal terhadap pola anomali geomagnetik yang terkait dengan aktivitas seismik.

Namun, meskipun sudah banyak penelitian yang menggarisbawahi potensi anomali geomagnetik ULF sebagai prekursor gempa bumi, masih ada beberapa kesenjangan penelitian yang perlu diisi. Beberapa kesenjangan penelitian diantaranya kebutuhan untuk validasi lebih lanjut dari temuan-temuan ini di berbagai wilayah seismik Indonesia dengan karakteristik geologis yang berbeda, frekuensi dominan yang emisi ULF di Indonesia dan juga tingkat akurasi prekursor. Sistem prekursor gempa bumi data magnet bumi BMKG saat ini, menggunakan pendekatan statistic dan matematik berupa analisis rasio perbandingan Z/H menghasilkan akurasi di bawah 70%. Penggunaan deep learning seperti Convolutional Neural Network (CNN) dengan data set yang sudah tersedia akan meningkatkan tingkat akurasi yang lebih baik.

1.2. Perumusan Masalah

Berdasarkan latar belakang di atas, maka permasalahan yang akan dikaji dalam penelitian ini adalah:

- a. Bagaimana cara mendeteksi prekursor seismik pada rekaman medan geomagnetik secara konsisten?
- b. Bagaimana cara mengatasi keterbatasan dataset yang diperlukan untuk melabeli prekursor seismik dengan akurat?
- c. Bagaimana cara mencapai sistem prediksi gempa bumi jangka pendek yang komprehensif meliputi magnitudo, lokasi, dan waktu kejadian gempa secara efektif?

1.3. Tujuan Penelitian

Tujuan umum dari penelitian ini adalah untuk mengembangkan model prediksi gempa bumi yang lebih akurat dengan memanfaatkan data anomali magnet bumi. Tujuan khusus dari penelitian ini adalah:

- a. Merancang dan mengimplementasikan algoritma deteksi prekursor seismik pada rekaman medan geomagnetik secara konsisten.

- b. Membuat data sintetik mengatasi keterbatasan dataset yang diperlukan untuk melabeli prekursor seismik dengan akurat.
- c. Membangun sistem prediksi gempa bumi jangka pendek yang komprehensif meliputi magnitudo, lokasi, dan waktu kejadian gempa secara efektif

1.4. Manfaat Penelitian

Hasil penelitian ini diharapkan dapat memberikan kontribusi dalam bidang mitigasi bencana gempa bumi. Secara spesifik, manfaat dari penelitian ini adalah:

- a. Ilmiah: Memperkaya pengetahuan tentang fenomena fisik yang terjadi sebelum gempa bumi dan hubungannya dengan anomali magnet bumi.
- b. Teknologi: Mengembangkan metode dan alat analisis data yang lebih baik untuk deteksi dini gempa bumi.
- c. Masyarakat: Meningkatkan kesiapsiagaan masyarakat terhadap bencana gempa bumi.
- d. Pemerintah: Memberikan informasi yang berguna untuk pengambilan keputusan dalam upaya mitigasi bencana.

1.5. Batasan Penelitian

Untuk memfokuskan penelitian ini, maka perlu ditetapkan beberapa batasan sebagai berikut:

- a. Wilayah Penelitian: Penelitian ini akan difokuskan pada wilayah dengan aktivitas seismik yang tinggi di Indonesia.
- b. Jenis Gempa Bumi: Penelitian ini akan menganalisis gempa bumi tektonik dengan magnitudo di atas tertentu.
- c. Data Anomali Magnet Bumi: Data yang digunakan adalah data anomali magnet bumi dari stasiun pengamatan yang tersebar di wilayah penelitian dari tahun 2018-2024.
- d. Metode Analisis: Metode analisis data yang digunakan akan dibatasi pada beberapa metode yang relevan dengan penelitian ini.

1.6. Kebaharuan Penelitian

Berbeda dengan model CNN yang hanya melakukan klasifikasi, penelitian ini mengembangkan sistem prediksi gempa yang komprehensif dengan mengintegrasikan data seismik, ionosferik, dan geosferik untuk membentuk satu framework prediksi yang lebih akurat dan holistik. Hal ini memungkinkan prediksi parameter gempa (magnitudo, lokasi, waktu) yang lebih mendetail. Selain itu, sistem prediksi yang dikembangkan dirancang untuk pengoperasian secara real-time dengan integrasi streaming data. Untuk ini, pendekatan online learning memungkinkan pembaruan model secara instan sehingga sistem dapat memberikan peringatan dini yang responsif terhadap perubahan kondisi lingkungan seismik di Indonesia.

1.7. State of the Art

Penelitian sebelumnya menunjukkan bahwa perubahan dalam medan magnet bumi dapat menjadi indikator awal terjadinya gempa bumi. Analisis anomali geomagnetik frekuensi ultra-rendah (ultra-low frequency / ULF) sebagai prekursor seismik telah menghasilkan sejumlah solusi inovatif yang diangkat dalam berbagai literatur ilmiah. Hasil penelitian memperlihatkan korelasi antara emisi frekuensi ultra-rendah magnet bumi dan gempa bumi, serta memberikan indikator yang kuat terkait aktivitas seismik di Sumatera (Hamidi et al., 2024a). Integrasi parameter geofisika ini menawarkan pendekatan multidisipliner yang dapat meningkatkan keandalan prediksi gempa bumi, dengan memanfaatkan variasi data yang komprehensif untuk mengidentifikasi tanda-tanda awal gempa bumi. Penelitian sebelumnya juga memberikan wawasan berharga dengan mendokumentasikan anomali geomagnetik ULF yang berhubungan dengan swarm gempa bumi di Kepulauan Pagai, Sumatera (Marzuki et al., 2022a). Temuan ini memperkuat hipotesis bahwa sinyal ULF dapat berfungsi sebagai prekursor gempa bumi yang efektif.

Penelitian mengenai deteksi sinyal prekursor gempa melalui data medan geomagnetik telah menunjukkan kemajuan signifikan dengan mengintegrasikan teknologi deep learning. Model CNN prospektif untuk mendeteksi sinyal seismik prekursor dalam rekaman medan geomagnetik dengan pendekatan supervised

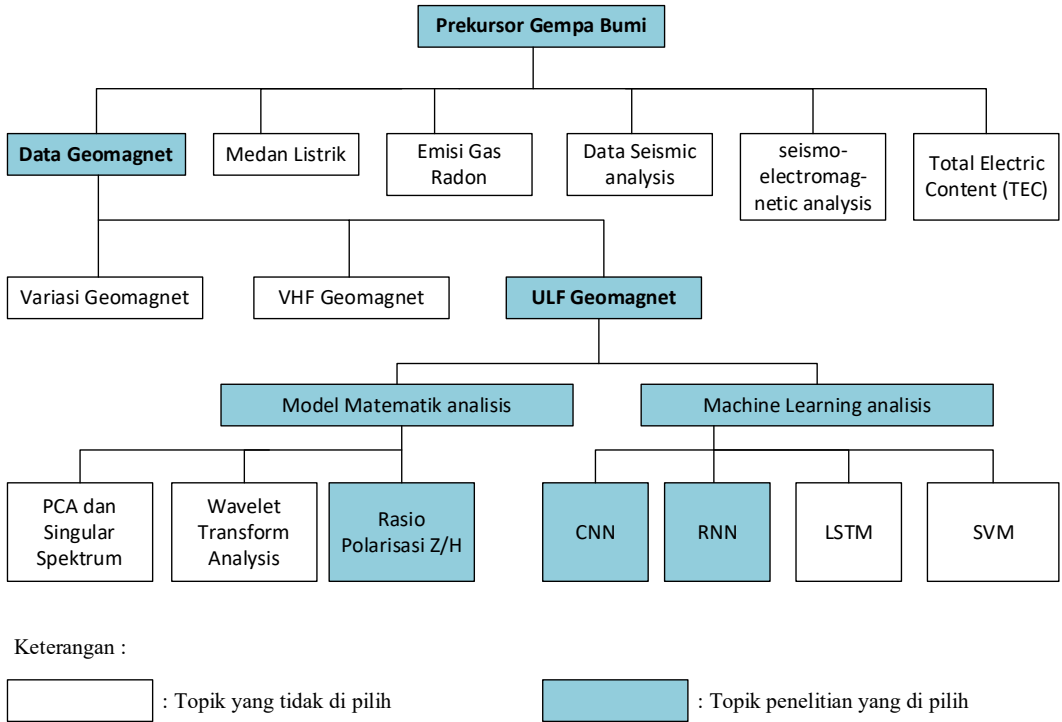
learning, yang membuktikan bahwa CNN mampu mengenali pola-pola terkait aktivitas seismogenik secara sistematis (Petrescu & Moldovan, 2022a). Pendekatan ini dapat mengidentifikasi pola anomali yang tidak mudah terlihat, melalui metode konvensional, dengan meningkatkan presisi deteksi anomali geomagnetik. Kombinasi pendekatan machine learning dengan analisis wavelet juga diperkenalkan untuk deteksi otomatis pulsasi geomagnetik (Pappoe et al., 2024). Hasil penelitian ini menunjukkan potensi besar dalam meningkatkan efisiensi dan akurasi deteksi prekursor gempa. Namun demikian, kedua contoh penelitian di atas hanya terbatas pada deteksi prekursor gempa, dan belum sampai pada prediksi gempa.

Model prediksi gempa berbasis Automated Machine Learning (AutoML) yang menggunakan CNN telah dikembangkan untuk mengekstraksi fitur dari data geomagnetik global (Yusof et al., 2021a). Pendekatan tersebut mengotomatisasi pemilihan algoritma dan tuning hyperparameter dengan algoritma asynchronous successive halving (ASHA), sehingga dihasilkan model klasifikasi dengan akurasi sekitar 83,29%. Namun demikian, model yang dihasilkan hanya mengklasifikasikan data menjadi dua kategori (gempabumi terjadi vs. tidak terjadi) tanpa menghasilkan prediksi parameter gempa seperti magnitudo, lokasi, atau waktu kejadian secara rinci.

Meskipun teknologi deteksi gempa bumi telah berkembang pesat, namun memprediksi waktu dan lokasi terjadinya gempa dengan tingkat akurasi yang tinggi masih menjadi tantangan besar. Banyak penelitian yang menggarisbawahi potensi anomali geomagnetik ULF sebagai prekursor gempa bumi, namun belum ada yang mengembangkan sistem deteksi ini menjadi sistem prediksi gempabumi yang komprehensif. Penelitian awal dilakukan oleh tim peneliti pada kasus gempa bumi Nusa Tenggara (Sumawan et al., 2024).

Model prekursor gempa bumi dengan metode machine learning dan deep learning sudah banyak dikembangkan dalam penelitian sebelumnya. Model jaringan saraf banyak digunakan dalam model prediksi gempa bumi, salah satu yang populer dengan *convolutional neural network* (CNN) dan *residual recurrent neural network* (RNN). Model CNN direkomendasikan sebagai model menjanjikan sebagai model prediksi kejadian gempa bumi di masa depan. Dari bermacam-

macam data dan model prekursor sudah dilakukan oleh para peneliti sebelumnya, penulis merancang penelitian ini dengan menggunakan model polarisasi data ULF magnet bumi sebagai penentuan data set dan menggunakan machine learning algoritma neural network sebagai model estimatornya. Gambaran peta jalan penelitian secara ringkas disajikan dalam Gambar 1.1.



Gambar 1.2 Peta Jalan Penelitian

BAB 2

TINJAUAN PUSTAKA

2.1. Penelitian Terdahulu

Penelitian ini disusun dengan memperhatikan referensi dari makalah internasional yang berhubungan dengan prekursor gempa bumi, data magnet bumi ultra rendah dan *machine learning* guna mendapatkan celah penelitian terkini sesuai dengan topik ini. Makalah-makalah yang dijadikan referensi merupakan penelitian yang sudah diterbitkan oleh jurnal internasional kurun waktu 5 tahun terakhir dan merupakan topik penelitian yang masih relevan.

Berdasarkan metode pengolahan makalah yang digunakan sebagai referensi dikelompokkan menjadi dua bagian. Kelompok pertama adalah makalah dengan pengolahan dengan metode statistik dan matematik yang mengolah sinyal elektromagnetik untuk menentukan anomali secara statistik korelasi sebelum kejadian gempa bumi (Hayakawa et al., 2021; Ouyang et al., 2020; Warden et al., 2020), wavelet (Febriani et al., 2021; Syed Zafar et al., 2024), polarisasi (Feng et al., 2022; Hamidi et al., 2024b; Stănică & Stănică, 2021) dan spektrum (Marzuki et al., 2022b; Yang et al., 2023; Yusof et al., 2021b). Penelitian kelompok ini menyajikan bukti-bukti keterkaitan anomali data ULF magnet bumi sebagai prekursor gempa bumi.

Kelompok yang kedua, pengolahan dengan metode *machine learning* dan *deep learning*. Metode *machine learning* memudahkan Analisa sinyal dan mengurangi kesalahan subyektif peneliti. Penelitian dengan *machine learning* dan *deep learning* menunjukkan bukti-bukti peningkatan akurasi prediksi gempa bumi yang lebih baik (Akyol et al., 2020; Antonopoulou et al., 2022; Bao et al., 2021; Cárdenas et al., 2022; Draz et al., 2023; Hao et al., 2022; Kavianpour et al., 2023; Miao et al., 2021; Mignan & Broccardo, 2020; Pappoe et al., 2023; Petrescu & Moldovan, 2022b; Rabie et al., 2021; Wu et al., 2024). Makalah yang sudah terbit di jurnal internasional yang sesuai dengan topik penelitian disajikan secara ringkas berikut ini :

Tabel 1.1 Rangkuman Referensi Yang Digunakan

No	Tahun	Referensi	Isi	Kelemahan
Penelitian Peningkatan Akurasi Sistem Prekursor Gempa Bumi Dengan ULF Magnet Bumi				
1	2020	Akyol, A. A.; Arian, O.; Arian, F., A machine learning-based detection of earthquake precursors using ionospheric data, Radio Science, 1944-799X	<ul style="list-style-type: none"> – Model pembelajaran mendalam berbasis LSTM – Perbandingan dengan pengklasifikasi SVM, LDA, dan Random Forest. – Prapemrosesan data: Pembersihan, Transformasi, dan Pengurangan. – Prapemrosesan data termasuk fase pembersihan, transformasi, dan reduksi. 	<ul style="list-style-type: none"> • Makalah ini tidak membahas prediksi gempa waktu nyata. • Eksplorasi terbatas sumber data ionosfer di luar TEC. • Kurangnya perbandingan dengan model pembelajaran mendalam lainnya. • Analisis tren data jangka panjang yang tidak memadai.
2	2020	Mignan, Arnaud; Broccardo, Marco, Neural network applications in earthquake prediction (1994-2019): Meta-analytic and statistical insights on	<ul style="list-style-type: none"> – Ulasan 77 artikel tentang aplikasi ANN untuk prediksi gempa bumi dan analisis tren kompleksitas model ANN dari waktu ke waktu. – Perbandingan model yang lebih sederhana versus model 	<ul style="list-style-type: none"> • Fitur terbatas dalam kumpulan data menghambat kemampuan prediktif. • Fitur terbatas dipertimbangkan dalam model prediksi gempa bumi.

		their limitations, Seismological Research Letters, 1938-2057	<p>pembelajaran mendalam yang kompleks, Model yang lebih sederhana sering cocok atau melebihi kekuatan prediksi.</p> <ul style="list-style-type: none"> – Evaluasi kekuatan prediksi berbagai model pembelajaran mesin dan pembelajaran mendalam menunjukkan harapan dalam prediksi gempa bumi. – Model dasar selaras dengan prinsip fisik dan hukum empiris. 	<ul style="list-style-type: none"> • Model yang lebih sederhana dapat mengungguli pendekatan pembelajaran mendalam yang kompleks. • Kebutuhan akan model pembelajaran mesin yang lebih transparan. • Model yang ada memiliki kemampuan prediksi minimal untuk gempa bumi besar
4	2020	Warden, Sheldon; MacLean, Laura; Lemon, Jim; Schneider, Dan, Statistical analysis of pre-earthquake electromagnetic anomalies in the ULF range, Journal of Geophysical Research:	<ul style="list-style-type: none"> – Menggunakan teknik analisis statistik. – Fokus pada anomali elektromagnetik pra-gempa bumi. – Analisis dilakukan dalam kisaran ULF. 	<ul style="list-style-type: none"> • Tidak membahas pola anomali elektromagnetik jangka panjang. • Eksplorasi terbatas dalam rentang frekuensi yang berbeda. • Kurangnya data komprehensif • Analisis faktor lingkungan tidak memadai.

		Space Physics,2169-9380, 2169-9402	– Temuan berkontribusi untuk memahami teknik prediksi gempa bumi.	
5	2020	Ouyang, X. Y.; Parrot, M.; Bortnik, J.,ULF wave activity observed in the nighttime ionosphere above and some hours before strong earthquakes,Journal of Geophysical Research: Space Physics,2169-9402	<ul style="list-style-type: none"> – Algoritma deteksi otomatis gelombang ULF dan analisis superimposed epoch analysis korelasi gelombang ULF dan gempa bumi. – Data dari satelit DEMETER – Korelasikan gelombang ULF dengan kejadian gempa bumi secara temporal dan spasial. – Peningkatan gelombang ULF yang signifikan berada dalam jarak 200 km dari pusat gempa dan satu minggu sebelum kejadian gempa bumi. – Korelasi lebih kuat untuk gempa bumi dengan magnitudo ≥ 5.0 dan 	<ul style="list-style-type: none"> • Studi terbatas yang menghubungkan gelombang ULF dan gempa bumi ada. • Kebutuhan akan kumpulan data aktivitas gelombang ULF yang besar dan andal. • Beberapa studi kasus tentang aktivitas gelombang ULF dan gempa bumi.

			tingkat signifikansi efek pra-gempa 0,1.	
6	2021	Bao, Zhenyu; Zhao, Jingyu; Huang, Pu; Yong, Shanshan; Wang, Xinâan, A deep learning-based electromagnetic signal for earthquake magnitude prediction, Sensors (Basel, Switzerland), 1424-8220	<ul style="list-style-type: none"> – Model CNN dengan peta fitur 3D untuk mengklasifikasikan magnitudo gempa bumi. – Menggabungkan blok Ekstraksi Fitur-Dimensi Tinggi dan blok Korelasi Temporal. – Teknik augmentasi data dengan teknologi simulasi kebisingan dan SMOTE (Teknik Pengambilan Sampel Minoritas Sintetis) untuk pengambilan sampel berlebihan. – Metrik evaluasi kinerja model menggunakan akurasi klasifikasi (ACC) – Membandingkan model CNN dengan SVM, Decision Tree, dan Random Forest. 	<ul style="list-style-type: none"> • Ketidakseimbangan Data Seismik dengan data magnetik mempengaruhi hasil estimasi • Model yang diusulkan menunjukkan akurasi tinggi dalam memprediksi magnitudo gempa bumi, penerapan sistem prediksi waktu nyata masih menjadi tantangan. • Kinerja model dapat bervariasi di seluruh wilayah geografis yang berbeda karena pola aktivitas seismik yang bervariasi. • Ada kesenjangan dalam mengembangkan model yang dapat memprediksi gempa bumi dalam jangka waktu yang lebih lama.

7	2021	Yusof, Khairul Adib; Abdullah, Mardina; Hamid, Nurul Shazana Abdul; Ahadi, Suaidi; Yoshikawa, Akimasa, Correlations between earthquake properties and characteristics of possible ULF geomagnetic precursor over multiple earthquakes, Universe, 2218-1997	<ul style="list-style-type: none"> – Menggunakan spektral (PSD) komponen vertikal (Z) dengan komponen bidang horizontal total (G), untuk mendeteksi prekursor ULF dan memperkenalkan normalisasi baru – Proses normalisasi melibatkan penyesuaian rentang S_G dan S_Z untuk memberi bobot lebih pada komponen Z, yang dianggap sebagai indikator utama anomali pra-gempa bumi 	<ul style="list-style-type: none"> • Belum membuat model estimasi manitudo dan predisksi lokasi gempa bumi. • Keterbatasan data yang digunakan. • Makalah ini mencatat bahwa banyak pasangan korelasi tidak memenuhi ambang signifikansi statistik ($p < 0,05$), menunjukkan bahwa penyelidikan lebih lanjut diperlukan untuk menetapkan model prediktif yang andal
8	2021	Rabie, Esraa; Hafez, Ali G.; Saad, Omar M.; El-Sayed, Abou-Hashema M.; Abdelrahman, Kamal; Al-Otaibi, Naif, Geomagnetic micro-pulsation automatic detection via deep leaning	<ul style="list-style-type: none"> – Menggunakan analisis resolusi bertingkat (MRA) dari DWT untuk mengekstrak fitur data geomagnetik. – Hubungan silang pola ULF yang dipilih secara arbitrer (Pm) dengan detail keenam dari catatan geomagnetik. 	<ul style="list-style-type: none"> • Penggunaan korelasi silang antara catatan geomagnetik dan pola ULF sebagai metode deteksi merupakan aspek inovatif lain dari penelitian ini.

		<p>approach guided with discrete wavelet transform, Journal of King Saud University - Science, 1018-3647</p>	<ul style="list-style-type: none"> – Algoritma kedua menggunakan CNN – CNN sangat efektif karena kemampuannya untuk mengekstrak fitur-fitur penting dari data deret waktu, meningkatkan kinerja keseluruhan tugas klasifikasi dan akurasi sekitar 91,11% 	<ul style="list-style-type: none"> • Belum membuat model estimasi manitudo dan predisksi lokasi gempa bumi. • Keterbatasan data yang digunakan sebagai data training.
9	2021	<p>Stanica, DragoË™ Armand; Stanica, Dumitru, Possible correlations between the ULF geomagnetic signature and mw6.4 coastal earthquake, albania, on 26 november 2019, Entropy. An International and Interdisciplinary Journal of Entropy and Information Studies, 1099-4300</p>	<ul style="list-style-type: none"> – Data dari dua observatorium geomagnetik: Panagjurishte (PAG) di Bulgaria dan Surlari (SUA) di Rumania (15 Oktober hingga 30 November 2019 – Menggunakan parameter polarisasi (BPOL) – Analisis statistik bertujuan untuk menyoroti singularitas sinyal anomali dalam deret waktu BPOL* (PAG) dan ABS BPOL* (PAG) 	<ul style="list-style-type: none"> • Penelitian menekankan korelasi antara tanda geomagnetik dan peristiwa seismik, belum ada estimasi besarnya magnitude dan perkiraan lokasi gempa bumi. • Penelitian menunjukkan metodologi untuk mengidentifikasi sinyal pra-seismik dapat ditingkatkan. • Penelitian di wilayah Balkan, khususnya Albania, Bulgaria, dan Rumania, keterbatasan data pada wilayah geografis.

			<ul style="list-style-type: none"> – Menggunakan band-pass transformasi Fourier cepat (FFT) frekuensi ultra-rendah (ULF) – Hasilnya divisualkan melalui model grafis dari deret waktu BPOL (PAG) dan BPOL (SUA) anomali geomagnetik prekursor 	<ul style="list-style-type: none"> • Integrasi data multi-parameter diperlukan untuk meningkatkan akurasi.
10	2021	Febriani, F; Ahadi, S; Anggono, T; Syuhada; Dewi, C N; Prasetyo, A D, Applying wavelet analysis to assess the ultra low frequency (ULF) geomagnetic anomalies prior to the M6.1 banten earthquake (2018), IOP Conference Series: Earth and Environmental	<ul style="list-style-type: none"> – Analisis wavelet data deret waktu geomagnetik. – Berfokus pada frekuensi 0,02 Hz untuk rasio kerapatan spektral. – Mengidentifikasi anomali geomagnetik ULF sebelum M 6.1 Banten EQ. – Indeks geomagnetik global Dst tidak menunjukkan kekhasan selama anomali. – Anomali mungkin terkait dengan terjadinya gempa Banten. 	<ul style="list-style-type: none"> • Studi ini tidak memiliki data ekstensif tentang peristiwa seismik lainnya. • Analisis terbatas pada rentang frekuensi yang berbeda di luar 0,02 Hz. • Tidak ada perbandingan dengan metode deteksi anomali geomagnetik lainnya. • Eksplorasi yang tidak memadai dari peran indeks geomagnetik global.

		Science,1755-1307, 1755-1315		<ul style="list-style-type: none"> • Kebutuhan validasi dengan studi kasus gempa tambahan.
11	2021	Hayakawa, Masashi; Izutsu, Jun; Schekotov, Alexander; Yang, Shih-Sian; Solovieva, Maria; Budilova, Ekaterina, Lithosphere atmosphere ionosphere coupling effects based on multiparameter precursor observations for February-march 2021 earthquakes (M 7) in the offshore of tohoku area of japan,Geosciences,2076-3263	<ul style="list-style-type: none"> – Pengamatan multiparameter tiga bulan (Januari hingga Maret) – Deteksi Radiasi ULF/ELF untuk mengidentifikasi anomali elektromagnetik sebelum gempa bumi – Membandingkan dua gempa bumi, mencatat kesamaan dalam magnitudo dan kedalamannya, sambil menyoroti perbedaan signifikan dalam kondisi geologi dan seismologisnya. 	<ul style="list-style-type: none"> • Keterbatasan data mempengaruhi hasil prediksi. • Belum membuat prediksi magnitudo dan estimasi lokasi gempa bumi. • Pengujian metode di wilayah lain untuk pembuktian model.
12	2022	Antonopoulou, Alexandra; Balasis, Georgios; Papadimitriou,	<ul style="list-style-type: none"> – Jaringan Saraf Konvolusi (ConvNet) untuk klasifikasi, K-Nearest (kNN) 	<ul style="list-style-type: none"> • Proses generasi dan propagasi gelombang ULF masih belum jelas.

		Constantinos; Boutsis, Adamantia Zoe; Rontogiannis, Athanasios; Koutroumbas, Konstantinos; Daglis, Ioannis A.; Giannakis, Omiros, Convolutional neural networks for automated ULF wave classification in swarm time series, Atmosphere, 2073-4433	<p>untuk klasifikasi dan SVM untuk penilaian kinerja.</p> <ul style="list-style-type: none"> – Transformasi wavelet dan Filter High-pass Butterworth untuk ekstraksi – Hasil akurasi set pelatihan 98,3%, akurasi pengujian mencapai 97,3% dan Heidke Skill Score dihitung pada 96,2. – Confusion matrix menunjukkan hasil yang hampir diagonal – Metodologi menjanjikan klasifikasi identifikasi gelombang Pc3 secara efisien. 	<ul style="list-style-type: none"> • Eksplorasi lebih lanjut metodologi klasifikasi gelombang ULF diperlukan. • Aplikasi terbatas model ke data satelit lainnya. • Kebutuhan akan pemahaman yang lebih baik tentang klasifikasi latar belakang kebisingan.
13	2022	Cardenas, J.; Denis, C.; Mousannif, H.; Camerlynck, C.; Florsch, N., Magnetic anomalies characterization: Deep	<ul style="list-style-type: none"> – Kombinasi YOLO dan DenseNet untuk lokalisasi dipol data EM – Identifikasi lapisan yang tidak digunakan dan alat t-SNE untuk prediksi model. 	<ul style="list-style-type: none"> • Terbatas penerapan pembelajaran mendalam dalam metode magnetik. • Kebutuhan akan database sintetis yang lebih kompleks.

		learning and explainability, Computers & Geosciences, 0098-3004	<ul style="list-style-type: none"> – Model dengan bentuk dan ukuran dipol yang berbeda. – Data noise tidak signifikan pengaruhnya pada data dipol sintetis. 	<ul style="list-style-type: none"> • Ketidakmampuan untuk mengidentifikasi beragam bentuk dan ukuran dipol. • Eksplorasi metode geofisika alternatif diperlukan.
14	2022	Marzuki, Marzuki; Hamidi, Muhammad; Ahadi, Suaidi; Putra, Ardian; Afdal, Afdal; Harmadi, Harmadi; Karnawati, Dwikorita; Suprihatin, Hendra Suwarta; Syirojudin, Muhammad; Marsyam, Indah, ULF geomagnetic anomaly associated with the Sumatra-Pagai Islands earthquake swarm during 2020, Contributions to	<ul style="list-style-type: none"> – Analisis data MAGDAS dan anomali ULF menunjukkan prekursor gempa bumi. – Metode kerapatan spektral daya untuk analisis emisi ULF dan metode standar deviasi untuk menentukan waktu onset emisi ULF. – Rumusan azimuth dengan akurasi azimuth rata-rata 97,8%. – Rumus empiris amplitudo anomali dan magnitudo gempa bumi, dengan hasil aktual sebesar 98,13%. 	<ul style="list-style-type: none"> • Bias prekursor dalam waktu dekat dan lokasi gempa bumi tetap belum terselesaikan. • Analisis terbatas pada anomali ULF dari wilayah geografis lain. • Perlunya metode yang ditingkatkan untuk memvalidasi sumber anomali. • Eksplorasi lebih lanjut dampak badai geomagnetik pada anomali diperlukan.

		Geophysics and Geodesy,1338-0540		
15	2022	Petrescu, Laura; Moldovan, Iren-Adelina,Prospective neural network model for seismic precursory signal detection in geomagnetic field records,Machine Learning and Knowledge Extraction,2504-4990	<ul style="list-style-type: none"> – Model CNN untuk mengklasifikasikan data geomagnetik dengan memindai jendela bergerak data geomagnetik tiga komponen tanpa filter – Kumpulan data geomagnetik di tiga zona tektonik utama di Eropa: MLR di Rumania, DUR di Italia, dan IZN di Turki serta katalog gempa lokal dari 2007 hingga 2021 – Penulis mengusulkan alur kerja yang tidak bias dan sistematis untuk menilai apakah data geomagnetik pra-gempa mengandung sinyal prekursor seismogenik yang konsisten. 	<ul style="list-style-type: none"> • Data tidak mencukupi untuk melatih model jaringan saraf konvolusi. • Kurangnya generator data sintetis untuk augmentasi data buatan. • Periode perekaman terbatas menghambat pengamatan prekursor seismik yang konsisten. • Kebutuhan algoritma yang mensimulasikan respons medan magnet terhadap pemuatan stres. • Tidak ada estimasi besaran magnitude prediksi dan lokasi gempa bumi.

16	2022	Feng, Lili; Qu, Rui; Ji, Yingfeng; Zhu, Weiling; Zhu, Ye; Feng, Zhisheng; Fan, Wenjie; Guan, Yiliang; Xie, Chaodi, Multistationary geomagnetic vertical intensity polarization anomalies for predicting M6 earthquakes in qinghai, china, Applied Sciences, 2076-3417	<ul style="list-style-type: none"> – Normalisasi data untuk analisis distribusi spasial. – MGVIPA menunjukkan kejadian berkelompok waktu sebelum gempa bumi besar. – Anomali MGVIPA bernilai tinggi muncul secara bersamaan di beberapa lokasi. – Gempa bumi $M_w \geq 6$ terjadi dalam waktu 3 bulan hingga 1 tahun. – 18 anomali bernilai tinggi diidentifikasi dari 2015 hingga 2021. – Gempa bumi sering mengelompok 	<ul style="list-style-type: none"> • Korelasi MGVIPA dengan gempa bumi kurang dipahami. • Penelitian sebelumnya terbatas tentang anomali GVIP multistasioner. • Jaringan geomagnetik jarang sebelum 2014 di China barat. • Butuh lebih banyak data tentang anomali dan waktu gempa. • Kurangnya analisis komprehensif tentang kejadian gempa yang dikelompokkan.
17	2022	Hao, Guocheng; Guo, Juan; Zhang, Wei; Chen, Yunliang; Yuen, David A., High-precision chaotic radial basis function neural network model: Data	<ul style="list-style-type: none"> – Mengusulkan model jaringan saraf fungsi basis radial yang acak. – Ini menggabungkan teori chaos dengan jaringan saraf fungsi basis radial. 	<ul style="list-style-type: none"> • Makalah ini tidak membahas kemampuan peramalan jangka panjang. • Eksplorasi terbatas dari sumber sinyal elektromagnetik lainnya.

		forecasting for the Earth electromagnetic signal before a strong earthquake, Geoscience Frontiers, 1674-9871	<ul style="list-style-type: none"> – Model memperkirakan tren intensitas yang mendasari data medan elektromagnetik. – Eksperimen verifikasi menggunakan data 3 dan 6 hari untuk pelatihan. – Model memperkirakan data medan elektromagnetik 14 dan 21 hari. 	<ul style="list-style-type: none"> • Kurangnya diskusi aplikasi pemantauan real-time. • Validasi tidak memadai dengan kumpulan data gempa yang beragam.
18	2023	Pappoe, Justice Allotey; Yoshikawa, Akimasa; Kandil, Ali; Mahrous, Ayman, A machine learning approach combined with wavelet analysis for automatic detection of Pc5 geomagnetic pulsations observed at geostationary orbits, Advances in Space Research, 0273-1177	<ul style="list-style-type: none"> – Model Cascade Forward Neural Network (CFNN) mendeteksi efektif denyut geomagnetik Pc5, mencapai akurasi deteksi 80%. – Teknik wavelet untuk analisis sinyal. – Filter Bandpass Butterworth untuk ekstraksi sinyal. – Transformasi wavelet Daubechies untuk dekomposisi sinyal. – Estimasi Risiko Tidak Bias Stein (SURE) untuk denoising. 	<ul style="list-style-type: none"> • Makalah ini tidak membahas kemampuan deteksi waktu nyata. • Eksplorasi terbatas model pembelajaran mesin alternatif. • Kurangnya perbandingan dengan teknik pemrosesan sinyal canggih lainnya. • Tidak ada diskusi tentang skalabilitas untuk kumpulan data yang lebih besar.

19	2023	Draz, Muhammad Umar; Shah, Munawar; Jamjareegulgarn, Punyaw; Shahzad, Rasim; Hasan, Ahmad M.; Ghamry, Nivin A., Deep machine learning based possible atmospheric and ionospheric precursors of the 2021 mw 7.1 japan earthquake, Remote Sensing, 2072-4292	<ul style="list-style-type: none"> – Deteksi dengan Deep Learning anomali terdeteksi sebelum dan sesudah gempa bumi. – Standar deviasi (STDEV) untuk identifikasi anomali. – Transformasi wavelet untuk analisis deret waktu. – Jaringan Autoregresif Nonlinier dengan model Input Eksogen (NARX). – Jaringan Memori Jangka Pendek Panjang (LSTM) untuk analisis pola dinamis. 	<ul style="list-style-type: none"> • Studi ini tidak memiliki data komprehensif dari beberapa peristiwa gempa bumi. • Eksplorasi terbatas parameter atmosfer lainnya di luar yang dianalisis. • Validasi model pembelajaran mesin yang tidak memadai dengan data real-time. • Kebutuhan untuk integrasi teknologi penginderaan jauh tambahan.
20	2023	Kavianpour, Parisa; Kavianpour, Mohammadreza; Jahani, Ehsan; Ramezani, Amin, A CNN-BiLSTM model with attention mechanism for	<ul style="list-style-type: none"> – Convolutional Neural Networks (CNN) untuk ekstraksi fitur. – Pendekatan Memori Jangka Pendek Panjang Dua Arah (BiLSTM) untuk pembelajaran dan prediksi gempa bumi. 	<ul style="list-style-type: none"> • Tidak ada pencapaian substansial dalam metode prediksi gempa yang diidentifikasi. • Perilaku nonlinier dan kacau mempersulit pelatihan pembelajaran mendalam.

		earthquake prediction, Journal of Supercomputing, 1573-0484	<ul style="list-style-type: none"> – Zero-Order Hold (ZOH) untuk pra-pemrosesan data dan Evaluasi menggunakan metrik RMSE, MAE, dan R^2. 	<ul style="list-style-type: none"> • Kebutuhan akan metodologi kinerja prediksi yang ditingkatkan disorot.
21	2023	Yang, Bai-Yi; Li, Zhong; Huang, Jian-Ping; Yang, Xu-Ming; Yin, Hui-Chao; Li, Zong-Yu; Lu, Heng-Xin; Li, Wen-Jing; Shen, Xu-Hui; Zeren, Zhima; Tan, Qiao; Zhou, Na, EMD based statistical analysis of nighttime pre-earthquake ULF electric field disturbances observed by CSES, Frontiers in Astronomy and Space Sciences, 2296-987X	<ul style="list-style-type: none"> – Dekomposisi mode empiris (EMD) untuk analisis sinyal ULF berkorelasi dengan gempa $\geq 5,0$. – Deteksi otomatis anomali gangguan pada medan Listrik berbasis entropi sampel. – Korelasi antara gempa bumi dan gangguan medan listrik ULF. – Lebih banyak gangguan yang diamati pada gempa bumi laut daripada gempa bumi darat. – Gempa berkekuatan lebih besar menunjukkan anomali yang lebih awal dan lebih luas. 	<ul style="list-style-type: none"> • Pengaruh aktivitas geomagnetik dan matahari pada anomali tidak jelas. • Analisis terbatas pada sumber gempa yang lebih dalam di atas kedalaman 40 km. • Kurangnya data komprehensif tentang penyebab gangguan non-seismik. • Eksplorasi variasi regional dalam pola anomali yang tidak memadai. • Kebutuhan untuk analisis temporal yang lebih luas di atas tiga tahun.

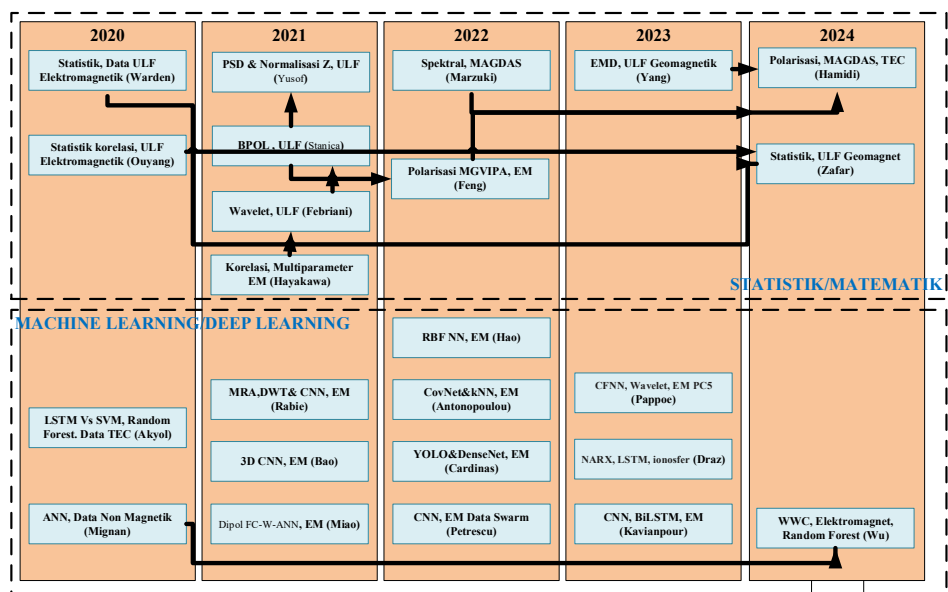
22	2024	Syed Zafar, S. N. A. Syed; Umar, R.; Hazmin, S. N.; Jusoh, M. H.; Yoshikawa, A.; Abe, S.; Uozumi, T.; Afandi, N. Z. M.; Mahiddin, N. A., Modelling of ULF Pc4 - Pc5 Pulsations with solar winds and geomagnetic storm for ULF earthquake precursor, <i>Advances in Space Research</i> , 0273-1177	<ul style="list-style-type: none"> – Korelasi statistik antara denyut ULF dan angin matahari. – Pendekatan model regresi berganda untuk penentuan hubungan variabel. – Metode regresi bertahap untuk mengidentifikasi faktor-faktor utama yang berkontribusi. – Pita Frekuensi ULF Pc5 paling cocok untuk model prekursor gempa bumi. – Faktor utamanya kecepatan angin matahari, tekanan, indeks geomagnetik. – Model membantu non-seismolog dalam mendeteksi peristiwa seismik. 	<ul style="list-style-type: none"> • Lingkup Data Terbatas di Davao, Filipina. • Keterbatasan Korelasi Statistik, ketergantungan pada korelasi tidak menyiratkan sebab-akibat. Perlu melibatkan variabel lain. • Model regresi berganda yang digunakan untuk menganalisis hubungan antar variabel mungkin terlalu menyederhanakan interaksi kompleks antara angin matahari, aktivitas geomagnetik, dan peristiwa seismik. •
23	2024	Hamidi, Muhammad; Ahadi, Suaidi; Friska, Vira; Marzuki, Marzuki, Investigating	<ul style="list-style-type: none"> – Menggunakan analisis rasio daya polarisasi untuk emisi ULF data MAGDAS. 	<ul style="list-style-type: none"> • Studi ini tidak mengeksplorasi metode prediksi gempa jangka panjang.

		ultra-low frequency emissions and total electron content anomalies as earthquake precursors in Sumatra (2019-2020),Kuwait Journal of Science,2307-4108	<ul style="list-style-type: none"> – Teknik Transfer Fungsi Tunggal untuk anomali ULF. – Teknik autokorelasi lanjutan untuk analisis anomali TEC data GPS Array (SuGAR). – Emisi ULF dan anomali TEC sebagai prekursor gempa bumi yang efektif. 	<ul style="list-style-type: none"> • Penyelidikan terbatas pada wilayah geografis lain di luar Sumatera. • Kurangnya analisis komprehensif tentang mekanisme emisi ULF. • Data yang tidak mencukupi tentang dampak faktor lingkungan. • Tidak ada eksplorasi efek gabungan anomali ULF dan TEC.
24	2024	Wu, Zongxuan; Xia, Jiening; Tan, Benyan; Wang, Bin; Zhao, Qian; He, Shaopeng, Detection and characterization of geomagnetic anomaly waveforms, Journal of Asian Earth Sciences, 1367-9120	<ul style="list-style-type: none"> – Metode derajat korelasi berbobot jendela (WWC), akurasi deteksi 0,976 dalam mendeteksi anomali. – Menghitung kesamaan antara data geomagnetik dan referensi. – Identifikasi sinyal abnormal berdasarkan nilai perubahan. – Model klasifikasi random forest mengukur penyimpangan non-acak. 	<ul style="list-style-type: none"> – Studi ini tidak mengeksplorasi mekanisme fisik anomali. – Analisis terbatas pada integrasi AI dalam prediksi gempa bumi. – Validasi lebih lanjut diperlukan untuk efektivitas metode WWC. – Data yang digunakan tidak dijelaskan secara detail pita frekuensinya.

Penelitian prekursor gempa bumi terdahulu memberikan kontribusi penting dalam peningkatan dan penemuan model prediksi yang lebih baik. Hasil penelitian tersebut dipengaruhi oleh jenis data dan model yang digunakan saat itu. Dari Tabel 2.1 rangkuman penelitian disajikan ringkasan hubungan antar pustaka beberapa penelitian terdahulu yang tersaji dalam Gambar 2.1.

Penelitian prekursor gempa bumi banyak menghasilkan makalah yang terbit di jurnal internasional ternama seperti scopus, web of science, nature dan banyak di indek di google scholar. Penelitian prekursor gempa bumi sangat penting untuk mendapatkan model prediksi yang akurat dan konsisten.

Berdasarkan studi literatur yang diuraikan sebelumnya, dirumuskan celah penelitian sistem prekursor gempa bumi menggunakan ULF magnet bumi di Indonesia, dengan algoritma CNN dan RNN dengan multi parameter dengan *self update*.



Gambar 2.1 Diagram Hubungan Antar Pustaka (Data diolah)

2.2. Dasar Teori

2.2.1. Teori Gempa Bumi

Indonesia menempati zona tektonik yang sangat aktif karena tiga lempeng besar dunia serta lempeng-lempeng kecil lainnya saling bertemu di wilayah Indonesia. Zona tektonik tersebut membentuk jalur-jalur pertemuan lempeng yang

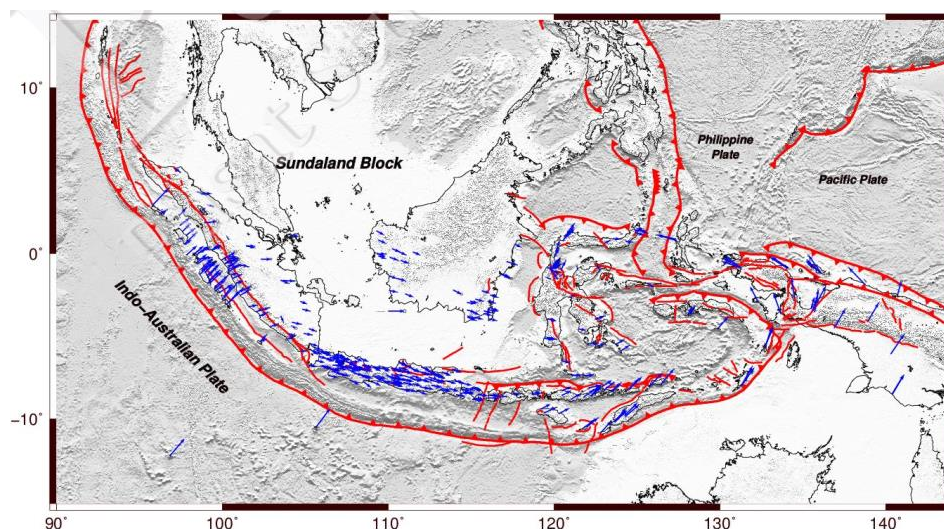
kompleks. Keberadaan interaksi antar lempeng-lempeng ini menempatkan wilayah Indonesia sebagai wilayah yang sangat rawan terhadap gempa. Sejak tahun 2010 beberapa penelitian terkait dengan parameter sumbergempa di Indonesia telah banyak dilakukan. Salah satu unsur penting dalam penelitian geologi gempa adalah melakukan pemetaan secara teliti mengenai lokasi jalur-jalur sesar aktif penghasil gempa dari bentukan morfologi akibat pergerakannya dan juga endapan kuarter di zona deformasinya. Kemudian, berdasarkan perkiraan umur endapan yang terdeformasi dan ukuran besar pergeserannya, maka parameter gempa dapat dihitung; yaitu kecepatan pergeseran sesar(sliprate), besar pergeseran atau ungkit setiap kejadian gempa, dan umur kejadian.

Gempabumi adalah fenomena geologis yang terjadi akibat pelepasan energi yang tiba-tiba di dalam lapisan bumi, yang menghasilkan gelombang seismik. Menurut teori tektonik lempeng, gempabumi biasanya terjadi di zona batas lempeng, di mana lempeng-lempeng tektonik saling bertabrakan, menjauh, atau bergeser satu sama lain. Proses ini dapat menyebabkan akumulasi stres yang akhirnya dilepaskan dalam bentuk gelombang seismik, menghasilkan gempabumi (Hayakawa, 2016).

Berdasarkan kedalaman pusat gempa bumi, dapat dibedakan menjadi gempa dangkal, menengah, dan dalam. Karena kedalaman berbeda gempa tersebut memiliki karakteristik dan dampak yang berbeda terhadap lingkungan. Gempabumi dangkal, misalnya, seringkali lebih merusak karena kedalamannya yang dekat dengan permukaan bumi. Data statistik menunjukkan bahwa lebih dari 80% gempabumi yang terdeteksi berada di kedalaman kurang dari 70 kilometer (Badan Meteorologi, Klimatologi, dan Geofisika, 2024). Selain itu, gempabumi dapat diklasifikasikan menjadi gempabumi tektonik, vulkanik, dan runtuh. Gempabumi tektonik, yang paling umum terjadi, disebabkan oleh pergerakan lempeng tektonik, sedangkan gempabumi vulkanik terjadi akibat aktivitas magma di dalam bumi. Runtuhan, di sisi lain, biasanya terjadi di area yang mengalami penurunan tanah dan bisa memicu tsunami jika longsoran yang terjadi cukup besar (Kurniawan et al., 2021).

Kondisi tektonik Indonesia yang terletak pada pertemuan lempeng besar dunia dan beberapa lempeng kecil atau microblocks, menyebabkan daerah tersebut

berpotensi mengalami banyak kejadian gempa. Indonesia dikelilingi oleh empat lempeng utama, yaitu Lempeng Eurasia, Lempeng Indo-Australia, Lempeng Laut Filipina, dan Lempeng Pasifik. Penelitian lanjutan menggunakan informasi geodetik, geologis, dan seismologis menunjukkan bahwa tektonik di Indonesia dapat dibagi ke dalam beberapa lempeng kecil, yaitu Burma, Sunda, Laut Banda, Laut Maluku, Timor, Kepala Burung, Maoke, dan Woodlark (Pusat Studi Gempa Nasional (Indonesia) & Pusat Penelitian dan Pengembangan Perumahan dan Permukiman (Indonesia), 2017). Salah satu sumber gempa yang telah jelas teridentifikasi adalah zona subduksi aktif di bagian barat hingga bagian timur Indonesia. Selain itu, sisa energi dari proses tumbukan antar lempeng tersebut akan mengakibatkan adanya sesar di daratan atau lautan di beberapa pulau dan laut Indonesia (Pusat Studi Gempa Nasional (Indonesia) & Pusat Penelitian dan Pengembangan Perumahan dan Permukiman (Indonesia), 2017). Perbatasan lempeng tektonik inilah yang sering terjadi gempa bumi tektonik yang berpotensi merusak bahkan jika kekuatannya besar dengan pusat gempa di laut bisa memicu tsunami.



Gambar 2.2 Peta Tektonik Wilayah Indonesia (Pusat Studi Gempa Nasional (Indonesia) & Pusat Penelitian dan Pengembangan Perumahan dan Permukiman (Indonesia), 2017)

Ada tiga faktor yang sangat mempengaruhi tingkat kerusakan lingkungan akibat gempa bumi yaitu kekuatan gempa bumi (magnitude), jarak sumber gempa bumi (epicenter) dan konstanta batuan dalam merespon guncangan gempa bumi.

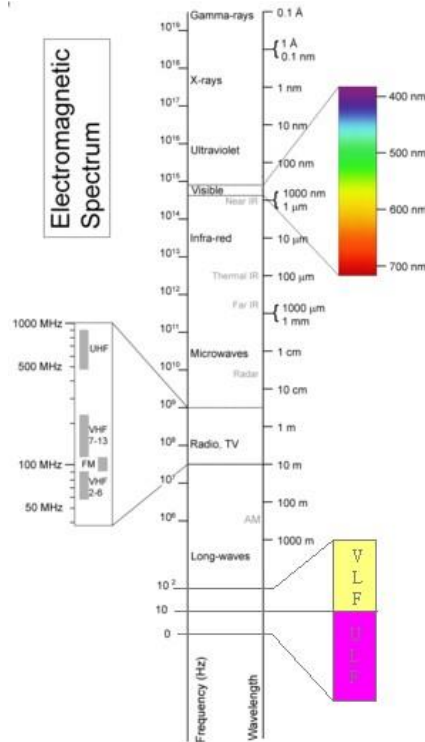
Semakin besar magnitude, semakin dekat epicenter dan dengan konstanta kerentanan yang tinggi akan menyebabkan kerusakan yang lebih besar. Pentingnya mempelajari teori gempa bumi tidak hanya terletak pada pemahaman tentang penyebabnya, tetapi juga pada upaya mitigasi risiko. Dengan mempelajari pola dan karakteristik gempa bumi, ilmuwan dapat mengembangkan model prediksi yang lebih akurat. Ini menjadi sangat relevan dalam konteks penelitian ini, di mana penggunaan deep learning untuk menganalisis data geomagnetik diharapkan dapat meningkatkan akurasi prediksi prekursor gempa bumi.

2.2.2. Data Ultra Low Frequency Magnet Bumi

Propagasi gelombang elektromagnetik dari alam (Natural) berjalan pada spektrum Ultra Low Frequency, ULF ($f < 10$ Hz) (Chi et al., 1996) baik dari akibat aktivitas Badai Matahari, Atmosfer maupun dari Aktivitas Litosfer yang disebut dengan LAI Coupling (lithosphere, atmosphere dan ionosphere) (Yumoto, 1986b). Pengukuran magnet bumi yang dilakukan dengan Variograph merekam pulsa magnet dengan periode 0.1 – 600 detik (Yumoto, 1986b, 1986a) dengan besaran medan magnet-bumi 30000 nT di ekuator dan 60000 nT di Kutub (Jankowski dan Sucksdorff, 1996). Spektrum Frekuensi gelombang elektromagnetik alam (nature) yaitu berkisar antara 10^{-8} – 10^2 Hz, jadi setiap gelombang elektromagnetik akan terekam baik dari gelombang elektromagnetik alam (Natural) maupun dari aktivitas kehidupan di Bumi. Untuk itu hasil dari rekaman variograph perlu ditapiskan sinyal elektromagnetik tersebut ($f < 10$ Hz) untuk mendapatkan spektrum ULF yang diasumsikan memiliki hubungan dengan aktivitas LAI coupling jika pada saat tersebut tidak terjadi badai Matahari maka dianggap sebagai aktivitas litosfer yang berasosiasi dengan gempa bumi, karena spektrum tersebut diyakini sebagai Prekursor gempa-bumi (Hayakawa et al., 2000, 2007).

Gelombang elektromagnetik memiliki spektrum frekuensi dari frekuensi tinggi sampai frekuensi rendah. Spektrum frekuensi alam adalah frekuensi rendah gelombang panjang seperti spektrum frekuensi gempa-bumi (ground motion) berkisar antara 0 – 100 Hz (Newmark dan Hall, 1982). Gambar 2.3 menunjukkan pembagian spektrum frekuensi dimana gelombang elektromagnetik terlihat (visible) memiliki kisaran 10¹⁵- 10¹⁶ Hz dan spektrum gelombang radio

komunikasi berkisar antara 105- 108 Hz dan untuk spektrum alam seperti ground motion gempa- bumi dan emisi elektromagnetik alam berkisar antara 0 – 100 Hz yang dikenal dengan very- low-frequency, VLF dan ultra-low-frequency,ULF.



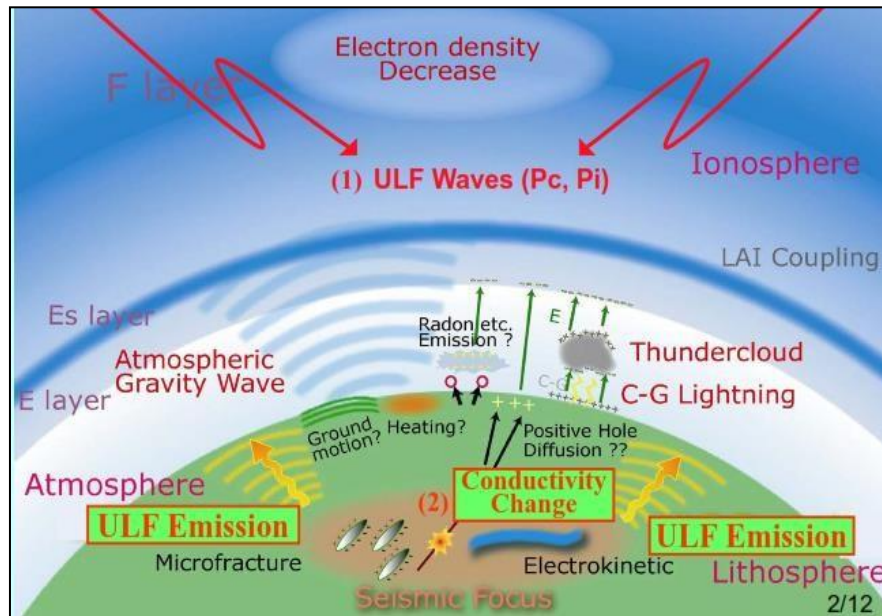
Gambar 2.3 Spektrum Frekuensi gelombang elektromagnetik (US Department of Commerce, 2003)

Spektrum gelombang panjang seperti ULF adalah gelombang elektromagnetik alam yang merupakan fungsi dari parameter *solar wind*, *Magnetospher*, *Ionospher* dan litosfer (Chi et al., 1996) yang di jelaskan dalam persamaan di bawah ini:

$$A = B f (LT)c \quad (2.1)$$

Dimana A, B, f dan c adalah amplitudo ULF yang diamati pada permukaan bumi yang tergantung pada musim, Waktu lokal (*local time*) dan Garis lintang geografis (Yumoto, 1996) merupakan fungsi parameter dari gelombang sumber yang berasal dari *solar wind*, *Magnetospher* dan tergantung dari ionosfer dan faktor amplifikasi dari *Lithospher*. Pada Gambar 2.4 menunjukan propagasi gelombang

elektromagnetik spektrum ULF yang berasal dari aktivitas matahari *solar wind*, *Magnetosphere*, *Ionosphere* dan aktivitas *Lithosphere* akibat gempa-bumi.



Gambar 2.4 Mekanisme fisis emisi ULF di sekitar lokasi sumber gempabumi (Hattori dkk., 2006)

Gelombang plasma ULF pada lapisan magnetosphere disebut juga magnetic pulsations continues (Pc). Pengkategorian Pc ini sangat bermanfaat untuk mengidentifikasi terkait sumber dari propagasi gelombang elektromagnetik tersebut. Klasifikasi dari Pc ini dapat dilihat pada Tabel 2.2. Secara umum precursor gempa bumi yang berasosiasi dengan study gelombang ULF adalah pada rentang Pc3-Pc5 (Currie & Waters, 2014).

Tabel 2.2 Klasifikasi Pc dan Pi Propagasi Gelombang ULF.

Pulsations	T , s	f	Amplitudes, nT
Pc 1	0.2–5	0.2–5 Hz	0.01–0.1
Pc 2	5–10	0.1–0.2 Hz	0.1–1
Pc 3	10–45	22–100 mHz	1–10
Pc 4	45–150	7–22 mHz	5–50
Pc 5	150–600	2–7 mHz	50–500
Pi 1	1–40	0.025–1 Hz	0.2–1
Pi 2	40–150	2–25 mHz	10–100

Menurut penelitian Kopytenko (Kopytenko et al., 2001), proses persiapan gempabumi bukan hanya diikuti oleh kejadian seismik dan tektonik, namun diikuti juga oleh kejadian elektromagnetik. Penelitian setelah itu yang dilakukan Ismaguilov dkk (2002), berhasil menghubungkan antara fenomena gempabumi dengan fenomena elektromagnetik, dimana fenomena elektromagnetik dianggap sebagai salah satu metode yang menjanjikan untuk prekursor jangka pendek suatu gempabumi besar. Salah satu metoda penentuan tanda-tanda akan terjadinya gempa yang sedang dikembangkan adalah dengan mendeteksi anomali sinyal *Ultra Low Frequency*(ULF). Telah diketahui bahwa dari semua frekuensi yang terlibat dari ULF sampai HF, hanya ULF yang dapat menghasilkan prekursor yang dapat dipercaya untuk gempa besar yang akan datang (Kushwah et al., 2005).

Peningkatan emisi ULF bisa dijadikan sebagai indikasi awal terjadinya gempabumi dan letak epicenter gempa yang akan terjadi berada di sekitar arah datangnya anomali emisi ULF tersebut (Ahadi et al., 2014b; Hattori, 2004). Maka dari itu emisi gelombang ULF dianggap sebagai fenomena yang paling menjanjikan untuk dapat digunakan sebagai prekursor jangka pendek yang dapat dipercaya (Kopytenko et al., 2001).

2.2.3. Fisis Sumber Emisi Seismo-Electromagnetik (SEM)

Seismo-Electromagnetik adalah hubungan antara fenomena yang terjadi pada litosfer (batuan kerak bumi) yang berkaitan dengan munculnya emisi gelombang elektromagnetik dalam rentang ULF sebelum terjadinya gempabumi. Emisi ULF yang dihasilkan tentunya tidak lepas dari pengaruh komposisi batuan pada kerak bumi yang mengandung mineral besi dan ion (partikel-partikel bermuatan). Stress maupun strain yang terakumulasi pada lapisan batuan di sepanjang bidang patahan sebelum terjadi gempabumi, menyebabkan adanya pelepasan dan aliran ion pada batuan tersebut sehingga menimbulkan arus listrik yang berkorelasi dengan perubahan medan magnet bumi (Freund et al., 2006).

Secara umum ada tiga macam mekanisme fisis emisi Seismo-Electromagnetik yang memungkinkan terjadinya anomali emisi ULF dan dapat

dideteksi perubahannya sampai ke permukaan bumi, sebagaimana yang dijabarkan oleh (Hattori et al., 2006) pada Gambar 2.4 antara lain :

- a. Efek Microfracturing, bahwa sebelum terjadi gempa bumi terdapat gaya yang terakumulasi serta tekanan yang bekerja pada batuan, sehingga pada medium batuan tersebut akan terbentuk retakan-retakan kecil yang merubah nilai permitivitas dielektrik ϵg dan konduktivitas dielektrik σg . Perubahan nilai permitivitas dan konduktivitas dielektrik tersebut selanjutnya memicu emisi gelombang elektromagnetik dalam rentang ULF yang terdeteksi oleh sensor di permukaan bumi (Molchanov & Hayakawa, 1998).
- b. Efek Electrokinetic, bahwa munculnya anomali elektromagnetik disebabkan karena adanya aliran fluida yang bergerak pada celah atau rekahan batuan yang banyak terkandung mineral silika dan ion-ion didalamnya (partikel bermuatan listrik). Pergerakan fluida yang mengalirkan mineral silika dengan kandungan ion-ion inilah yang menghasilkan arus listrik dan berkorelasi dengan munculnya gangguan medan magnet yang dapat terdeteksi oleh sensor di permukaan bumi (Fenoglio et al., 1995).
- c. Efek Induksi, bahwa terjadi gangguan pada konduktivitas dielektrik disekitar lokasi sumber gempa bumi akibat adanya tekanan atau stress pada batuan. Perubahan konduktivitas dielektrik tersebut kemudian terinduksi melalui medium kerak bumi (litosfer) sehingga terjadi perubahan amplitudo medan magnet yang terukur di permukaan bumi. Perubahan amplitudo medan magnet inilah yang selanjutnya dianalisis dan dijadikan sebagai salah satu parameter prekursor gempa bumi (Merzer & Klemperer, 1997).

2.2.4. Stasiun Pencatat Data Magnet Bumi

Informasi prekursor gempa bumi merujuk pada tanda-tanda atau anomali yang dapat diamati sebelum terjadinya gempa bumi. Sebelum terjadi gempa bumi ditemukan anomali data variasi harian pada stasiun pencatat data magnet bumi. Stasiun pencatat tersebut mengoperasikan magnetometer dari Magnetik Acquisition Data System (MAGDAS) dengan frekuensi kerja 1 hertz. Penelitian mengenai prekursor gempa bumi telah menjadi fokus utama dalam geofisika, karena kemampuan untuk memprediksi gempa bumi dapat mengurangi risiko dan dampak

dari bencana alam ini. Prekursor ini dapat berupa perubahan fisik, kimia, atau elektromagnetik yang terjadi di dalam atau di sekitar zona patahan. Gambar 2.5 menunjukkan peta sensor magnet bumi untuk prekursor BMKG di wilayah Indoensia.



Gambar 2.5 Peta Sensor Magnet Bumi Untuk Prekursor BMKG

Salah satu jenis prekursor yang paling banyak diteliti adalah anomali geomagnetik. Penelitian oleh Pulinets (Pulinets & Ouzounov, 2018) menunjukkan bahwa variasi medan magnet bumi dapat dihubungkan dengan peningkatan tegangan di zona patahan sebelum gempa. Anomali ini sering kali sulit dideteksi dengan metode tradisional, tetapi dengan penerapan teknologi deep learning, analisis data geomagnetik dapat dilakukan dengan lebih efektif.

2.2.5. Metode Prekursor Gempa Bumi

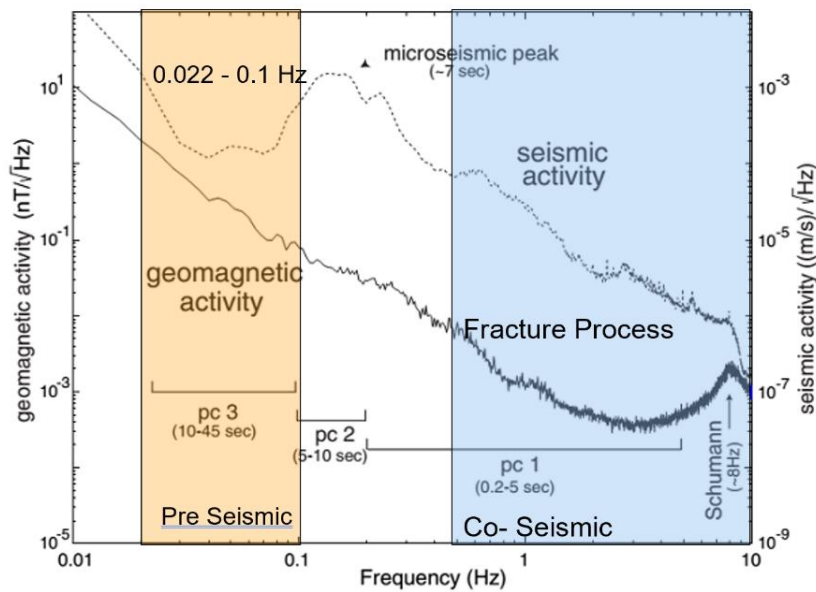
Metode prekursor dengan data magnet bumi melibatkan pengukuran medan magnet bumi untuk mendeteksi perubahan yang dapat menjadi indikator aktivitas seismik. Medan magnet bumi dihasilkan oleh arus listrik yang mengalir di dalam inti bumi, dan variasi medan magnet dapat memberikan informasi penting tentang proses geologis yang terjadi di dalam bumi. Penelitian menunjukkan bahwa anomali medan magnet dapat terjadi sebelum gempabumi, dan pengukuran ini dapat dilakukan dengan menggunakan stasiun geomagnetik yang tersebar di seluruh dunia (Xiang et al., 2022).

Studi prediksi gempabumi dengan menggunakan data anomali magnet bumi sebagai prekusornya sudah lama dilakukan banyak ahli di berbagai negara, diantaranya Smith dan Johnston (1976) melaporkan adanya kenaikan total komponen medan magnet bumi sebesar 1,5 sebelum terjadinya gempabumi dengan magnitudo 5,2 SR dekat Hollister, California 28 Nopember 1974. Kenaikan nilai magnet bumi terekam pada stasiun permanen medan magnet bumi yang terpasang pada jarak 10 km sebelah selatan episenter. Kenaikan nilai magnet bumi ini terjadi sekitar 7 minggu berturut-turut sebelum terjadinya gempabumi tersebut.

Beberapa teori tentang kemunculan anomaly emisi gelombang electromagnetic dalam interval frekuensi ULF yang mendahului gempabumi perlu direvisi. Adanya model numerik yang lebih simple tanpa matematika yang rumit. Para ahli mengusulkan beberapa fenomena-fenomena yang dipertimbangkan sebagai landasan teori, diantaranya teori Electrokinetic effects, Seismo-inductive effects, Filtration of underground liquid, Charge relaxation related with micro-crack formation, Large-scale current systems produced by dislocations or water evaporation, Geomagnetic inductive effects caused by acoustic impulses from micro-crack, Plasma Oscillation, dan lain sebagainya.

Dalam pengolahan prekursor gempabumi menggunakan metoda magnet bumi, diasumsikan bahwa semua aktivitas preseismik menghasilkan anomali emisi ULF yang dapat terekam oleh magnetometer. Kemampuan magnetometer dalam mendeteksi anomali emisi ULF bergantung pada potensi magnitudo dan jarak hiposenter terhadap sensor. Frekuensi yang digunakan dalam pengolahan adalah di frekuensi ULF ($F < 0.1$ Hz) dimana frekuensi ini merepresentasikan informasi dari sumber gempa (Molchanov & Hayakawa, 1998). Korelasi antara gelombang elektromagnetik dan gelombang seismik ditampilkan pada Gambar 2.6.

Dengan kemajuan teknologi dan metode analisis data yang semakin canggih, penggunaan metode magnet bumi dalam penelitian gempabumi diharapkan dapat memberikan kontribusi signifikan dalam upaya mitigasi risiko. Ini penting, mengingat dampak besar yang dapat ditimbulkan oleh gempabumi terhadap masyarakat dan lingkungan.



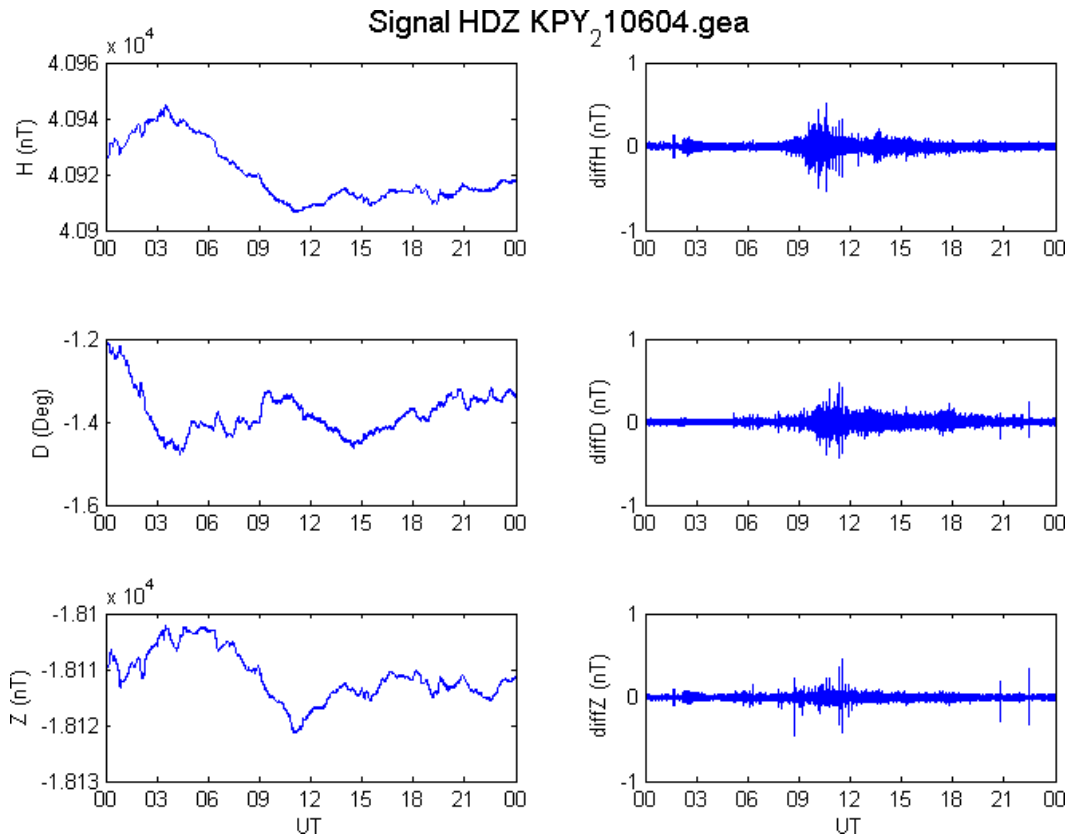
Gambar 2.6 Korelasi antara gelombang elektromagnetik dan gelombang seismik (Karakelian et al., 2000)

2.2.6. Prosesing Sinyal Untuk Penentuan Onset Time

Penentuan anomali medan magnetic yang bersumber dari proses microcracking didalam bumi seperti halnya mencari jarum dalam tumpukan jerami. Anomali tersebut tersembunyi dalam sinyal medan magnetic yang terecord oleh alat dipermukaan bumi. Hal ini tentu memerlukan tahapan untuk menyaring sinyal tersebut agar diperoleh anomali yang tepat. Pertama yaitu membaca raw data medan magnet yang merupakan output dari alat variometer. Pada tahap ini data dibaca dan diplotting untuk dilakukan quality control. Data yang baik adalah data yang memiliki nilai diff kurang dari absolute 1. Tampilan plotting raw data seperti tampak pada Gambar 2.7.

Data magnet bumi yang terekam oleh magnetometer berupa raw data harian, mencatat variasi magnet bumi yang timbul oleh intervensi internal dan eksternal dan juga mencatat semua noise lokal setempat. Noise lokal ini setiap stasiun pengamatan berbeda-beda dan terjadi sesaat, tidak sepanjang hari. Setelah diketahui kondisi raw data tersebut, tahap selanjutnya adalah melakukan koreksi data. Koreksi ini dilakukan dengan tujuan menghilangkan nilai spike diff yang dominan pada data. Hal ini dilakukan agar data yang akan diproses untuk mendapatkan nilai

anomali yang bersumber dari microcracking batuan dalam bumi sudah terbebas dari artifisial noise ataupun noise lingkungan. Nilai tersebut akan dikoreksi dengan nilai trend harian medan magnet bumi pada stasiun tersebut. Data hasil koreksi disajikan pada Gambar 2.8.

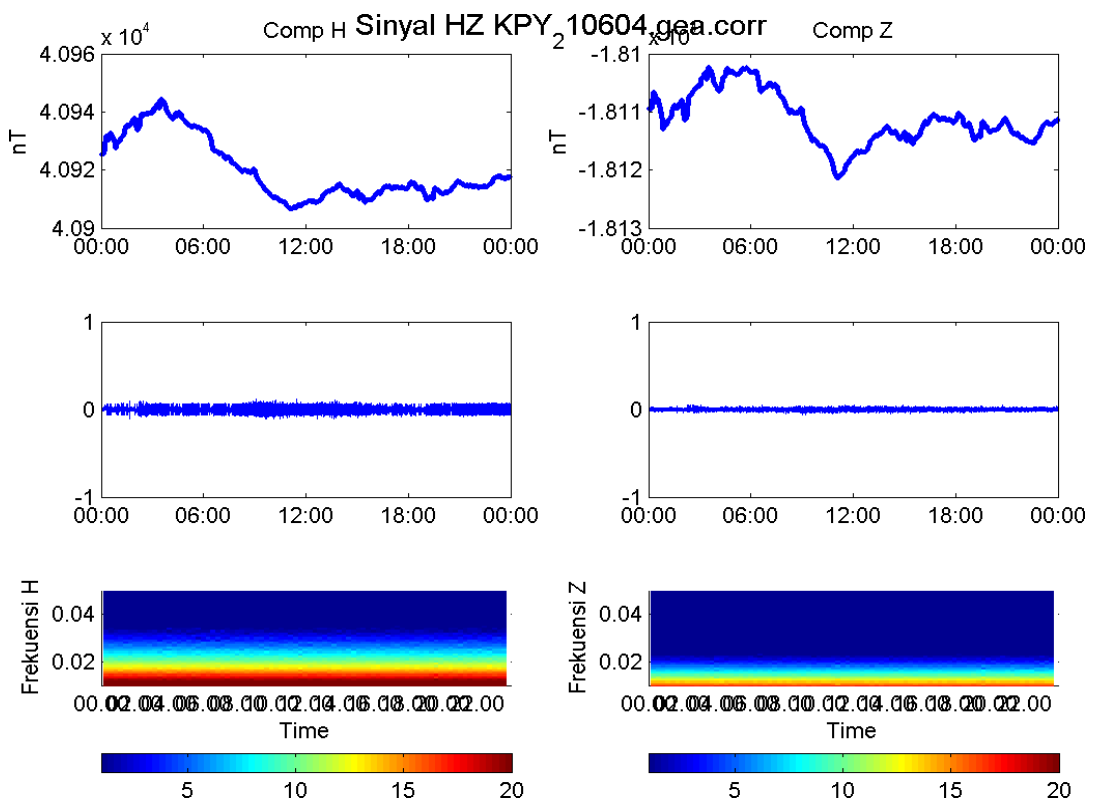


Gambar 2.7 Raw Data Harian Magnet Bumi

Setelah data dilakukan koreksi, selanjutnya dilakukan pengolahan sinyal untuk mendeteksi anomali. Pada tahap ini sinyal medan magnet bumi harian komponen Z (vertical) dan H (horizontal) yang terdiri dari dari komponen X dan komponen Y, disaring pada *bandpass filter* di domain frekuensi Pc3 (22 – 100 mHz) dan Pc4 (7 – 22 mHz). Komponen Z memiliki sensitifitas paling baik terhadap sumber yang berasal dari anomali local ataupun microcracking sedangkan komponen H sebagai data penguat ketika terjadi anomali. Hal ini dikarenakan komponen H sensitif terhadap gangguan medan magnet bumi eksternal. Metode deteksi anomaly rasio Z/H menghasilkan anomali microcacking yang terlihat jelas dengan mempertimbangkan karakteristik masing-masing komponen data magnetik

tersebut. Sinyal hasil penyaringan yang dilakukan bandpass Pc3 dan hasil anomali metode Z/H di sajikan pada Gambar 2.9 dan Pc4 Gambar 2.10.

Setelah diperoleh nilai amplitudo polarisasi rasio Z/H setiap jam, selanjutnya dipilih standar deviasi minimum yaitu absolut 2. Amplitudo yang lebih besar daripada deviasi minimum tersebut dicurigai sebagai anomali yang bersumber dari microcacking precursor gempabumi dan dipilih sebagai onset time.

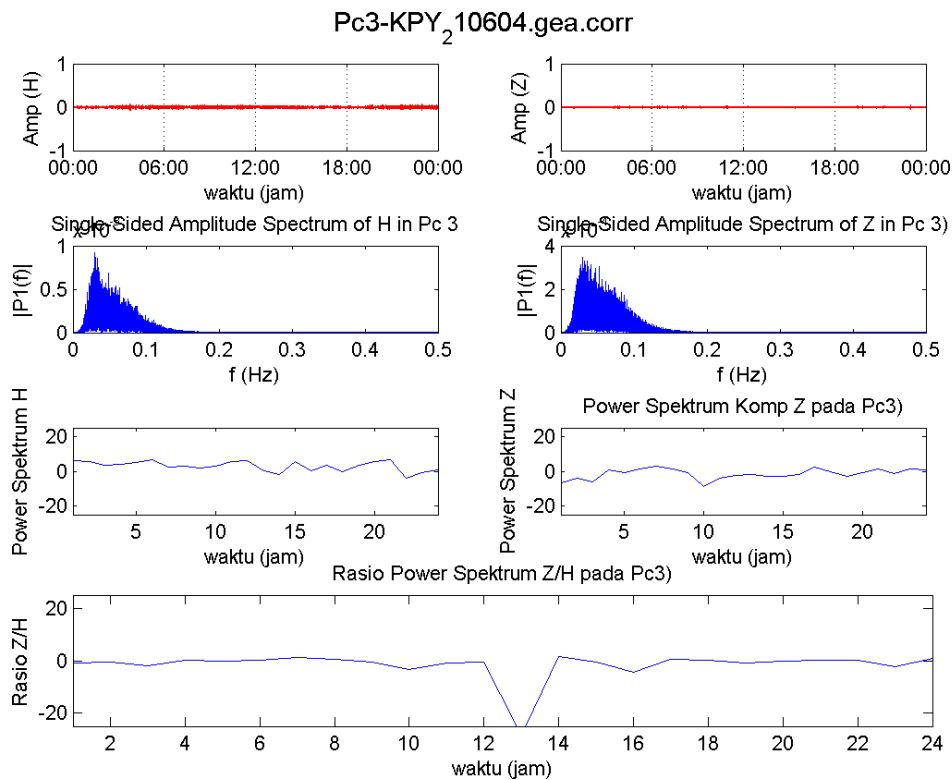


Gambar 2.8 Hasil Koreksi Raw Data Magnet Bumi (Data diolah)

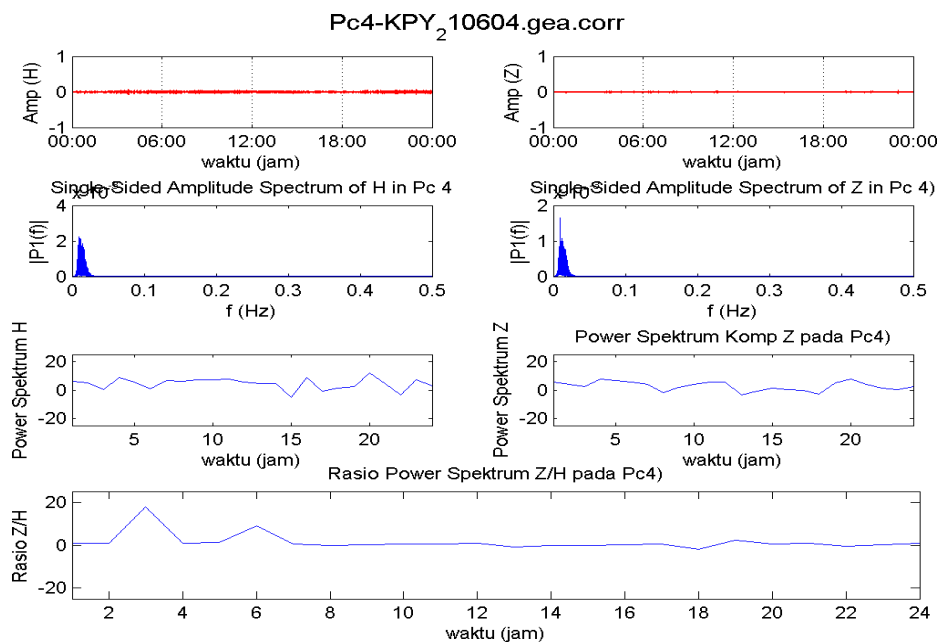
2.2.7. Penentuan Azimuth Anomali

Setelah diperoleh onset time, data komponen X, Y dan Z pada rentang jam tersebut dihitung azimuthnya. Arah Azimut sumber anomali microcacking digunakan metode fungsi transfer Single Station untuk mengamati anomali konduktifitas bumi pada satu stasiun. Metode ini pertama kali dikenalkan oleh Hattori (2004) dimana fungsi transfer tersebut dapat menyelesaikan suatu persamaan dari komponen X, Y dan Z geomagnet. Fungsi transfer merupakan fungsi dari komponen bilangan kompleks Fourier. Hubungan ini ditafsirkan sebagai

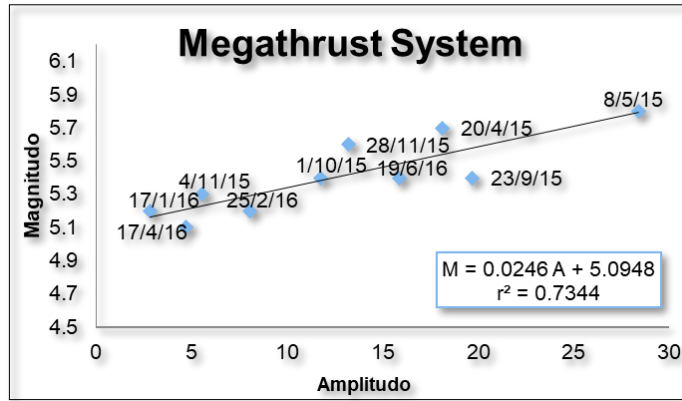
sistem linier yang memiliki dua masukan (input) dan satu keluaran (output). Koefisien dianggap invarian pada durasi tertentu. Fungsi transfer memiliki informasi tentang konduktifitas listrik di bawah tanah yang disebut dengan CA (Conductivity Anomali).



Gambar 2.9 Hasil Pengolahan ULF Magnet Bumi Pc3 (Data diolah)



Gambar 2.10 Hasil Pengolahan ULF Magnet Bumi Pc4 (Data diolah)



Gambar 2.11 Grafik koefisien determinasi, koefisien korelasi, dan standar deviasi

$$\Delta Z(\omega) = A(\omega) \cdot \Delta X(\omega) + B(\omega) \cdot \Delta Y(\omega) \quad (2.2)$$

dalam persamaan matrik:

$$\begin{bmatrix} \Delta X1XrXi & \Delta Y1YrYi \\ \Delta XnXrXi & \Delta Y1YrYi \end{bmatrix} * \begin{bmatrix} AArAi \\ BBrBi \end{bmatrix} = \begin{bmatrix} Z1ZrZi \\ ZnZrZi \end{bmatrix}$$

kemudian disederhanakan menjadi:

$$[G][m] = [\delta] \quad (2.3)$$

Inversi :

$$G \cdot m = \delta \quad (2.4)$$

$$m = [GT \ G]^{-1} GT \cdot \delta \quad (3.5)$$

$$Amp(\omega) = \sqrt{Ar(\omega)^2 + Br(\omega)^2} \quad (2.6)$$

$$Dir = \arctan \left(\frac{Br(\omega)}{Ar(\omega)} \right) \quad (2.7)$$

dimana :

Amp = skala konduktivitas (jarak antara medan konduktivitas)

Dir = arah arus dari bawah stasiun (arah medan konduktivitas)

Θ deg (derajat) = sudut dari arah Utara searah jarum jam

Hasil dari analisis fungsi transfer tersebut adalah skala konduktivitas (Amp) yang dihitung dari jarak medan konduktivitas, arah azimuth (Dir) dari bawah stasiun geomagnet yang sudutnya diawali dari arah utara ($\Theta = N = 0^\circ$) searah dengan jarum

jam. Hasil prakiraan azimuth ini mempunyai toleransi $\pm 22.5^\circ$ berdasarkan pada sebaran data yang telah diperoleh dalam waktu 1 tahun pengamatan.

2.2.8. Penentuan Magnitudo

Magnitudo prediksi merupakan parameter yang sangat penting dalam prediksi gempabumi. Hal ini dikarenakan besar kecilnya efek kerusakan gempabumi ditentukan oleh besarnya magnitudo. Sehingga magnitudo memiliki peran yang sangat krusial dan juga sensitive bagi prediksi gempabumi. Dalam penentuan magnitudo prediksi gempabumi digunakan persamaan empiris dengan analisis statistic. Persamaan empiris tersebut diharapkan dapat memberikan prediksi magnitudo yang baik, karena berasal dari data historis.

Pada tahun 2017, informasi prekursor Gempabumi yang dibuat sudah menyertakan potensi Magnitudo gempabumi. Persamaan empiris Potensi Magnitudo untuk gempabumi yang diprediksi berdasarkan rekaman kejadian gempabumi di sekitar megathrust Sumatra dan nilai rasio Power Spektrum Z/H (Amplitudo) yang diperkirakan berasosiasi dengan prekursor gempabumi tersebut selama satu tahun terakhir, yaitu tahun 2016. Diperoleh hubungan empiris antara magnitudo gempabumi dengan nilai rasio Power Spektrum Z/H (Amplitudo) sebagai berikut:

$$M = A * 0.0246 + 5.0948 \quad (2.8)$$

dimana:

M = Magnitudo Gempabumi

A = Amplitudo atau nilai rasio power spectrum Z/H

Persamaan regresi tersebut diatas mempunyai koefisien determinasi (r^2) = 0,7344 , dan standar deviasi (σ) 0,228279 seperti terlihat pada grafik sebagai berikut:

Berdasarkan rekaman kejadian gempabumi di sekitar megathrust Sumatra dan nilai rasio Power Spektrum Z/H (Amplitudo) yang diperkirakan berasosiasi dengan prekursor gempabumi tersebut selama dua tahun terakhir dan dengan menambahkan faktor jarak, diperoleh hubungan empiris antara magnitudo gempabumi dengan nilai rasio Power Spektrum Z/H (Amplitudo) sebagai berikut:

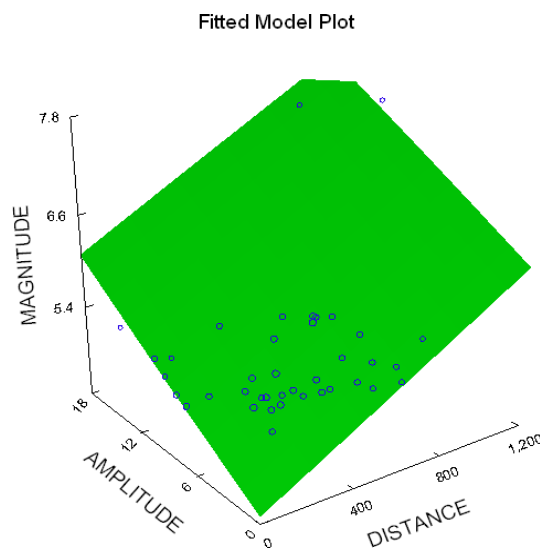
$$M = A * 0.1 + R * 0.002 + 4.288 \quad (2.9)$$

dimana:

M = Magnitudo Gempabumi

A = Amplitudo atau nilai rasio power spectrum Z/H R = Jarak Stasiun ke titik tengah daerah arsiran

Persamaan regresi tersebut diatas mempunyai koefisien determinasi (r^2) = 0,724 , koefisien korelasi (r) = 0,85088 dan standar deviasi (σ) 0,228279 seperti terlihat pada grafik sebagai berikut:



Gambar 2.12 Grafik koefisien determinasi, koefisien korelasi, dan standar deviasi

2.2.9. Convolutional Neural Network

Jaringan saraf konvolusi atau *Convolutional Neural Networks* (CNN) adalah jaringan saraf tiruan feed-forward yang dalam di mana jaringan saraf mempertahankan struktur hierarkis dengan mempelajari representasi fitur internal dan menggeneralisasi fitur dalam masalah gambar umum seperti pengenalan objek dan masalah penglihatan komputer lainnya. Itu tidak terbatas pada gambar; itu juga mencapai hasil mutakhir dalam masalah pemrosesan bahasa alami dan pengenalan suara. Convolutional Neural Network (CNN) telah menunjukkan kinerja yang sangat baik dalam banyak masalah visi komputer dan pembelajaran mesin. Banyak

makalah yang solid telah diterbitkan mengenai topik ini, dan beberapa paket perangkat lunak CNN sumber terbuka berkualitas tinggi telah tersedia.

2.2.9.1. Arsitektur CNN

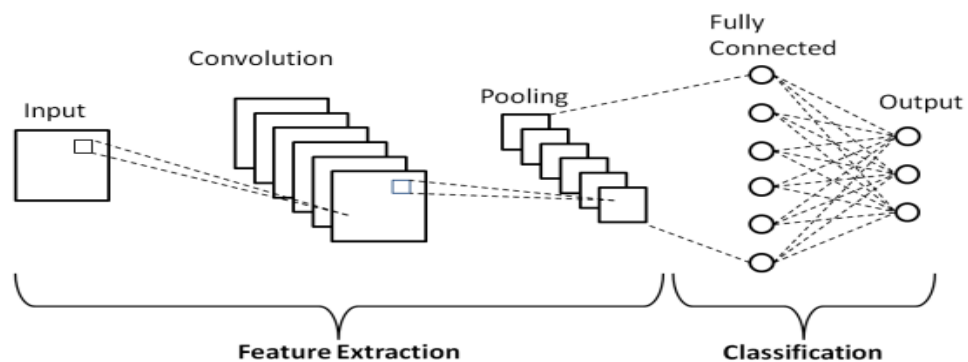
Jaringan syaraf tiruan konvolusi memiliki lapisan masukan, lapisan keluaran, banyak lapisan tersembunyi, dan jutaan parameter yang memiliki kemampuan untuk mempelajari objek dan pola yang kompleks. Ia mengambil sub sampel masukan yang diberikan melalui proses konvolusi dan pengumpulan dan dikenakan fungsi aktivasi, di mana semua ini adalah lapisan tersembunyi yang terhubung sebagian dan pada akhirnya adalah lapisan yang terhubung penuh yang menghasilkan lapisan keluaran. Keluaran mempertahankan bentuk asli yang mirip dengan dimensi gambar masukan.

Arsitektur CNN biasanya mengambil tensor orde 3 sebagai inputnya, misalnya, gambar dengan H baris, W kolom, dan 3 saluran (saluran warna R, G, B). Sebagai input tensor orde lebih tinggi dapat ditangani oleh CNN dengan cara yang sama. Input tersebut kemudian secara berurutan melalui serangkaian pemrosesan. Satu langkah pemrosesan biasanya disebut lapisan, yang dapat berupa lapisan konvolusi, lapisan pengumpulan, lapisan normalisasi, lapisan terhubung penuh, lapisan kerugian, dll. Kami akan memperkenalkan detail lapisan ini nanti dalam catatan ini. Secara umum tiga jenis lapisan yaitu konvolusi, penggabungan, dan ReLU, yang merupakan bagian utama dari hampir semua model CNN. Normalisasi yang tepat, seperti normalisasi batch atau normalisasi lintas lapisan penting dalam proses pengoptimalan parameter yang baik dalam CNN. Arsitektur CNN secara ringkas sebagai berikut :

- a. Lapisan konvolusi (convolutional layer) adalah lapisan yang bertujuan untuk mengekstrak fitur-fitur lokal dari gambar dengan filter yang disebut kernel. Kernel merupakan matriks kecil yang digunakan untuk mendeteksi fitur tertentu dalam gambar. Jadi konvolusi adalah proses pergeseran filter pada seluruh gambar untuk menghasilkan feature map.
- b. Fungsi aktivasi (activation function) merupakan proses untuk menambahkan non-linearitas ke jaringan. Beberapa fungsi aktivasi yang

paling umum digunakan dalam CNN yaitu ReLU, Sigmoid, softmax dan tanh.

- c. Lapisan Pengumpul (pooling layer) adalah sebuah proses mengurangi dimensi feature map dan mengurangi overfitting, jenis yang sering digunakan dalam CNN antara lain Max pooling, average pooling.
- d. Fully Connected Layer merupakan proses mengklasifikasikan fitur-fitur yang telah diekstrak untuk dikelompokkan selanjutnya di proses di output dengan kalsifikasi ataupun regresi. Proses kalsifikasi dengan distribusi probabilitas dan regresi dengan perhitungan matematik.



Gambar 2.13 Diagram skema arsitektur jaringan saraf konvolusional (CNN)

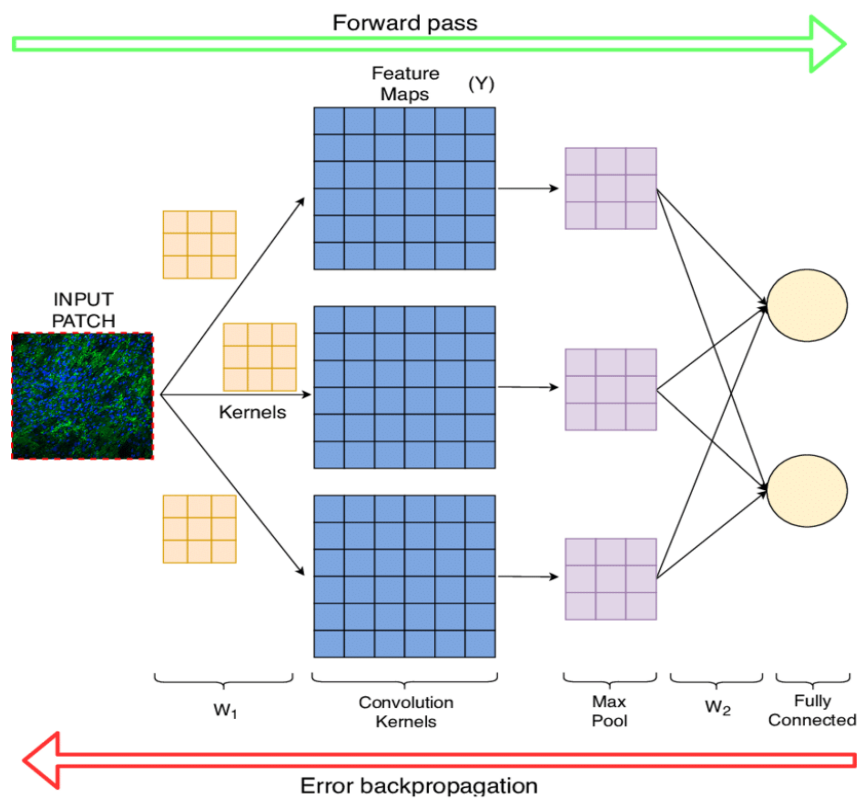
2.2.9.2. Proses Arah Maju dan Propagasi Balik

Sistem analisis maju (*forward pass*) pada CNN adalah proses di mana sebuah input (biasanya gambar) diproses melalui jaringan saraf untuk menghasilkan output (misalnya, klasifikasi gambar, deteksi objek, atau segmentasi) secara berurutan melewati setiap lapisan. Proses ini melibatkan perhitungan berulang-ulang pada setiap lapisan dalam jaringan. Pada proses analisis maju (*forward pass*) beberapa inputan (gambar) diumpankan ke jaringan, kemudian jaringan melakukan perhitungan pada setiap lapisan, menghasilkan output akhir (prediksi). Selisih antara prediksi dan label sebenarnya (error) dihitung menggunakan fungsi loss.

Propagasi balik (mundur) adalah algoritma yang digunakan untuk melatih jaringan saraf tiruan, termasuk CNN. Proses propagasi mundur, error dari proses maju dipropagasikan mundur melalui jaringan, mulai dari lapisan output menuju lapisan input. Pada setiap lapisan, gradien dari fungsi loss terhadap bobot dan bias dihitung. Bobot dan bias kemudian diperbarui menggunakan algoritma optimasi

(misalnya, Gradient Descent) untuk meminimalkan error. Algoritma ini memungkinkan jaringan untuk menyesuaikan bobot dan biasnya secara iteratif agar dapat membuat prediksi yang lebih akurat. Jika diibaratkan, propagasi mundur adalah proses belajar dari kesalahan.

Proses pelatihan CNN menggunakan backpropagation dan lintasan maju melalui CNN menghitung aktivasi neuron. Kesalahan antara keluaran dan kebenaran dasar yang diketahui dikirim kembali melalui CNN untuk menghitung gradien kesalahan sehubungan dengan bobot (sebagai ilustrasi W_1 dan W_2). Kemudian, penurunan gradien digunakan untuk memperbarui bobot. Diagram analisis maju (*forward pass*) dan propagasi mundur CNN disajikan dalam gambar berikut ini.



Gambar 2.14 Diagram analisis maju dan propagasi mundur.

2.2.9.3. Penurunan Gradien Stokastik

Penurunan gradien stokastik (*Stochastic Gradient Descent*, SGD) adalah sebuah algoritma optimasi yang digunakan untuk menemukan nilai minimum dari suatu fungsi. Dalam konteks pembelajaran mesin, fungsi yang ingin diminimalkan adalah fungsi kehilangan (loss function), yang mengukur seberapa jauh prediksi

model dari nilai sebenarnya. SGD bekerja dengan memperbarui parameter model (bobot dan bias) secara iteratif dalam arah yang berlawanan dengan gradien fungsi kehilangan.

Proses SDG dimulai dengan pembagian data pelatihan, dibagi menjadi beberapa batch yang lebih kecil. Setelah dilakukan penghitungan gradien untuk setiap batch, model melakukan forward pass untuk menghasilkan prediksi. Kemudian, error (perbedaan antara prediksi dan label sebenarnya) dihitung dan gradien dari fungsi kehilangan terhadap parameter model dihitung. Langkah berikutnya memperbarui parameter model dengan mengurangi learning rate dikalikan dengan gradien. Proses ini terus berulang, untuk beberapa epoch (iterasi) hingga model mencapai kinerja yang diinginkan atau mencapai kriteria penghentian lainnya.

Penggunaan SGD dalam CNN bertujuan untuk efisiensi komputasi, pencapaian konvergensi yang lebih cepat dan sebagai Langkah menghindari masalah lokal minimum. Dengan memproses data dalam batch yang lebih kecil, SGD membutuhkan memori yang lebih sedikit dan waktu komputasi yang lebih cepat dibandingkan dengan menghitung gradien pada seluruh dataset sekaligus. SGD seringkali dapat mencapai konvergensi yang lebih cepat daripada metode optimasi lainnya, terutama pada dataset yang besar. Dengan memperbarui parameter secara stokastik, SGD cenderung untuk keluar dari titik minimum lokal dan menemukan minimum global.

2.2.9.4. Kesalahan Propagasi Balik

Dalam suatu model prediksi output yang dihasilkan berbeda dengan data aktualnya, selisih antara nilai prediksi dan nilai aktual ini dianggap kesalahan. Kesalahan propagasi balik (*Error backpropagation*) pada CNN adalah proses menghitung dan menyebarkan kembali kesalahan (error) dari output jaringan ke lapisan-lapisan sebelumnya. Tujuannya adalah untuk memperbarui bobot dan bias pada setiap lapisan agar model dapat membuat prediksi yang lebih akurat.

Model CNN dilatih dengan memberikan sejumlah besar data pelatihan yang terdiri dari pasangan input (misalnya, gambar) dan label (kelas yang benar). Ketika model membuat prediksi, hasil prediksi ini seringkali tidak persis sama dengan

label sebenarnya. Selisih antara prediksi dan label inilah yang disebut error. Bobot dan bias yang belum optimal pada saat awal pelatihan, sehingga bobot dan bias pada setiap lapisan CNN diinisialisasi secara acak. Ini berarti model belum "belajar" untuk membuat prediksi yang akurat.

2.2.9.5. Optimasi CNN

Optimasi CNN adalah proses penyesuaian parameter (bobot dan bias) dalam model CNN agar dapat mencapai kinerja terbaik. Tujuan utama optimasi adalah meminimalkan kesalahan prediksi (loss) dan meningkatkan akurasi model. Selain itu optimasi juga bertujuan agar proses Analisa lebih cepat dan penggunaan sumber daya komputasi lebih hemat.

Langkah-langkah Umum dalam Optimasi CNN diantaranya pengaturan arsitektur jaringan, inisialisasi bobot, fungsi loss, algoritma optimasi dan hyperparameter tuning. Dalam arsitektur jaringan CNN penting untuk menentukan berapa banyak lapisan konvolusi, pooling, dan fully connected yang diperlukan, menentukan jumlah dan ukuran filter pada setiap lapisan konvolusi dan memilih fungsi aktivasi yang tepat untuk setiap lapisan (misalnya, ReLU, sigmoid, tanh). Metode inisialisasi bobot yang baik (misalnya, Xavier, He) untuk menghindari masalah vanishing atau exploding gradient dan pemilihan fungsi loss yang sesuai dengan jenis masalah (misalnya, binary cross-entropy untuk klasifikasi biner, categorical cross-entropy untuk klasifikasi multi-kelas) merupakan bagian dari optimasi CNN. Penggunaan algoritma estimasi yang tepat mempengaruhi kinerja model CNN. Gradient Descent adalah algoritma dasar untuk memperbarui bobot berdasarkan gradien dari fungsi loss, mempunyai banyak varian seperti Stochastic Gradient Descent (SGD), Adam, RMSprop, yang memiliki kelebihan masing-masing. Hyperparameter Tuning dilakukan dengan mengatur kecepatan pembaruan bobot, mengatur jumlah sampel data yang digunakan dalam satu iterasi, pencapaian epoch yang optimal dan pengaturan regulasi untuk mencegah overfitting (misalnya, L1/L2 regularization, dropout).

BAB 3

METODOLOGI PENELITIAN

Penelitian dilakukan dalam beberapa tahap untuk mencapai sistem prediksi gempa bumi jangka pendek yang komprehensif, khususnya dengan mendeteksi sinyal prekursor seismik pada rekaman medan geomagnetik yang dilakukan pada tahun pertama penelitian; dan mengintegrasikan hasil deteksi dengan data pendukung lainnya untuk memprediksi gempabumi secara komprehensif di tahun kedua penelitian. Diagram alir penelitian ditunjukkan pada Gambar 1 dengan tahapan sebagai berikut:

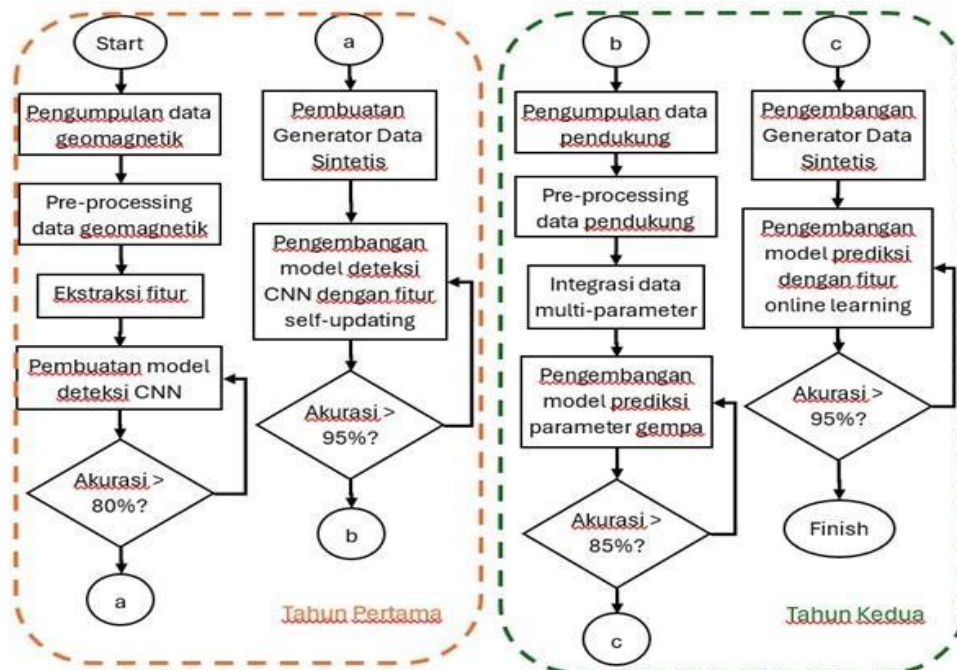
3.1. Pengumpulan dan Persiapan Data Pendukung

Data medan geomagnetik dikumpulkan dari stasiun magnetometer di BMKG dengan rentang waktu yang cukup panjang. Data mencakup fluktuasi medan magnet dari komponen H, D dan Z yang mengalami perubahan sesaat sebelum terjadi gempabumi. Data seismik dan katalog gempa dikumpulkan untuk melengkapi proses pelabelan dan validasi. Selanjutnya dilakukan pembersihan data untuk menghilangkan noise eksternal dan normalisasi pada masing-masing komponen (N, E, Z). Normalisasi untuk memastikan semua variabel berada dalam skala yang sama, yang sangat penting dalam algoritma pembelajaran mesin. Jika satu variabel memiliki rentang nilai yang jauh lebih besar dibandingkan variabel lainnya, menyebabkan model tidak berfungsi dengan baik [9]. Data yang tidak valid dihapus untuk memastikan bahwa model yang dibangun memiliki basis data yang solid. Data geomagnetik akan dilabeli berdasarkan informasi dari katalog gempa dengan menetapkan label “seismic” pada periode yang mendahului kejadian gempa (misalnya 7–11 hari sebelum gempa) dan “non-seismic” pada periode yang tidak terjadi gempa. Proses pelabelan ini menjadi dasar bagi pelatihan model CNN.

Tahapan penelitian dirancang untuk memastikan bahwa setiap langkah dalam pengembangan model deep learning dilakukan secara sistematis dan terstruktur. Tahap awal adalah pengumpulan data yang telah dibahas sebelumnya, di mana data magnet bumi dan informasi terkait lainnya dikumpulkan dan disimpan dalam

format yang dapat diakses. Penggunaan platform penyimpanan data yang efisien sangat penting untuk memudahkan analisis selanjutnya (Garcia et al., 2021).

Setelah pengumpulan data, tahap berikutnya adalah preprocessing data. Proses ini mencakup pembersihan data, normalisasi, dan transformasi data agar sesuai dengan kebutuhan model deep learning. Normalisasi diperlukan untuk memastikan bahwa semua variabel berada dalam skala yang sama, yang sangat penting dalam algoritma pembelajaran mesin. Apabila salah satu variabel memiliki rentang nilai yang jauh lebih besar dibandingkan variabel lainnya, hal ini dapat menyebabkan model tidak berfungsi dengan baik (Zhang et al., 2022). Dalam penelitian ini tahapannya disajikan dalam diagram alir pada gambar 3.1.



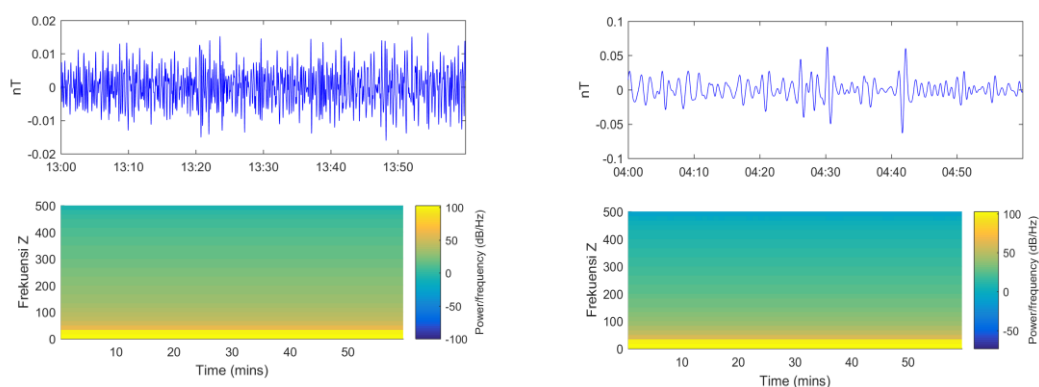
Gambar 3.1. Diagram Alir Penelitian (Rancangan, diolah)

3.2. Ekstraksi Fitur

Data medan geomagnetik dikumpulkan dari stasiun magnetometer di BMKG dengan rentang waktu yang cukup panjang. Data mencakup fluktuasi medan magnet dari komponen H, D dan Z yang mengalami perubahan sesaat sebelum terjadi gempabumi. Data seismik dan katalog gempa dikumpulkan untuk melengkapi proses pelabelan dan validasi. Selanjutnya dilakukan pembersihan data

untuk menghilangkan noise eksternal dan normalisasi pada masing-masing komponen (N, E, Z). Normalisasi untuk memastikan semua variabel berada dalam skala yang sama, yang sangat penting dalam algoritma pembelajaran mesin. Jika satu variabel memiliki rentang nilai yang jauh lebih besar dibandingkan variabel lainnya, menyebabkan model tidak berfungsi dengan baik [9]. Data yang tidak valid dihapus untuk memastikan bahwa model yang dibangun memiliki basis data yang solid. Data geomagnetik akan dilabeli berdasarkan informasi dari katalog gempa dengan menetapkan label “seismic” pada periode yang mendahului kejadian gempa (misalnya 7–11 hari sebelum gempa) dan “non-seismic” pada periode yang tidak terjadi gempa. Proses pelabelan ini menjadi dasar bagi pelatihan model CNN.

Dalam penelitian ini data yang digunakan untuk analisis prekursor gempabumi dikumpulkan dari berbagai sumber yang kredibel, yaitu data pengukuran magnet bumi yang diambil dari stasiun-stasiun observasi yang tersebar di wilayah rawan gempa di seluruh Indonesia. Penelitian sebelumnya menunjukkan bahwa perubahan dalam medan magnet bumi dapat menjadi indikator awal terjadinya gempabumi (Kobayashi et al., 2020). Data yang diambil mencakup parameter seperti fluktuasi medan magnet dari komponen H, D dan Z yang mengalami perubahan sesaat sebelum terjadi gempa bumi. Gambar 3.2 ditampilkan spektrogram ULF data magnet PC 3 dan PC 4, pada komponen Z stasiun LIWA.



Gambar 3.2. Spektrogram ULF data magnet PC 3 (a) dan PC 4 (b), pada komponen Z stasiun LIWA (sumber data : BMKG, diolah).

Statistik menunjukkan bahwa dari tahun 2000 hingga 2020, lebih dari 60% gempabumi yang terjadi di Indonesia dapat diprediksi dengan menggunakan data magnet bumi, dengan tingkat akurasi yang bervariasi antara 60% hingga 70% (Badan Meteorologi, Klimatologi, dan Geofisika, 2021). Dalam meningkatkan akurasi model, hasil yang diperoleh juga akan dianalisis menggunakan teknik statistik untuk mengidentifikasi pola dan hubungan antara variabel yang ada. Metode analisis seperti regresi dan analisis komponen utama (PCA) akan digunakan untuk memahami lebih dalam tentang faktor-faktor yang mempengaruhi sinyal magnetik (Chen et al., 2021). Dengan pendekatan ini, diharapkan dapat ditemukan indikator yang lebih kuat untuk memprediksi gempabumi di masa depan.

Tahap penyusunan data set merupakan tahapan yang krusial dalam model deep learning, kesalahan data set akan membuat akurasi prediksi akan rendah. Data set inputan yang digunakan untuk data pelatihan dan data pengujian merupakan data ULF magnet bumi yang sudah di validasi sebagai prekursor gempa bumi di seluruh wilayah Indonesia dengan sampel data tahun 2018 – 2024 yang berkorelasi dengan gempa bumi. Tahap ini terbagi tiga proses, yaitu desain, pelatihan dan validasi serta evaluasi model. Model CNN dirancang untuk membaca windowed segments rekaman medan geomagnetik yang diperlakukan sebagai citra. Model dilatih dengan data yang telah dilabeli sebagai “seismic” dan “non-seismic” melalui pendekatan supervised learning. Metode evaluasi seperti confusion matrix, precision, recall, dan F1-score akan digunakan untuk memberikan gambaran yang jelas mengenai kemampuan model dalam melakukan klasifikasi dan estimasi (Sokolova & Lapalme, 2009).

Pelatihan dilakukan dengan optimasi hyperparameter, misalnya menggunakan algoritma Adam. Validasi kinerja model dilakukan dengan metrik seperti akurasi, precision, recall, F1-score, dan Matthews correlation coefficient, untuk memastikan model dapat mendeteksi sinyal prekursor secara konsisten. Proses validasi dilakukan menggunakan dataset pengujian yang belum digunakan dalam pelatihan agar terukur kemampuan model dalam menggeneralisasi pengetahuan yang diperoleh dari data pelatihan ke data baru (Ian Goodfellow and Yoshua Bengio and Aaron Courville, 2016).

Tahap preprocessing diawali dengan pembersihan data, di mana data yang memiliki nilai hilang atau tidak konsisten akan diidentifikasi dan ditangani. Menurut Han et al. (2011), data yang tidak bersih dapat mengakibatkan distorsi dalam hasil analisis dan pemodelan, sehingga penting untuk memastikan bahwa data yang digunakan adalah data yang berkualitas. Langkah normalisasi data dilakukan setelah data bersih dari nilai-nilai menyimpang dari *base line* data magnet bumi. Normalisasi dilakukan untuk mengubah skala dari variabel yang berbeda menjadi satu skala yang sama, biasanya antara 0 dan 1. Hal ini dilakukan untuk menghindari dominasi dari satu variabel terhadap variabel lainnya dalam proses pelatihan model. Apabila salah satu variabel memiliki rentang nilai antara 0 hingga 1000, sedangkan variabel lainnya hanya antara 0 hingga 10, maka variabel pertama akan memiliki pengaruh yang jauh lebih besar dalam model (Jain et al., 2020).

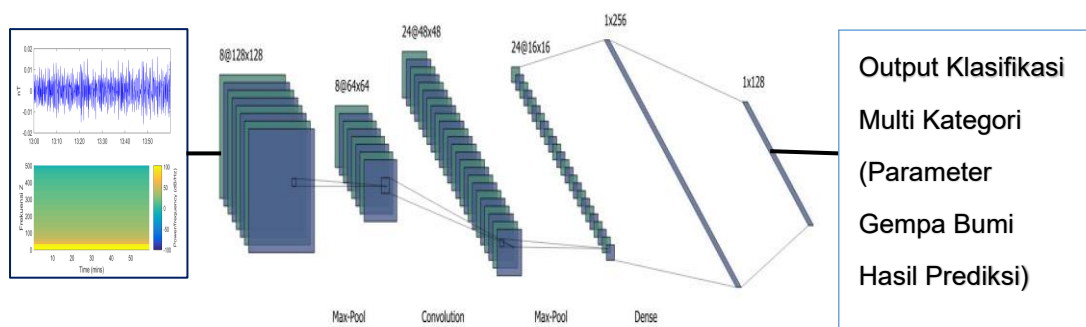
3.3. Pembuatan Model Deteksi Menggunakan CNN

Pembuatan model deteksi prekursor gempa bumi dari data geomagnetik merupakan inti dari penelitian ini, yang bertumpu pada kapabilitas CNN untuk ekstraksi fitur dan klasifikasi pola. Pada tahap desain arsitektur model, secara fundamental mengubah paradigma analisis data deret waktu. Dalam pendekatan ini, segmen-segmen data geomagnetik yang telah melalui proses windowing tidak lagi diperlakukan sebagai sekuens temporal linier, melainkan ditransformasikan menjadi representasi visual layaknya sebuah citra. Transformasi ini krusial karena memungkinkan CNN untuk menerapkan filter konvolusi, yang sangat efektif dalam mengidentifikasi pola spasial lokal. Dalam konteks ini, pola spasial secara konseptual merepresentasikan korelasi dan fluktuasi dalam segmen data geomagnetik pada skala waktu yang berbeda.

Arsitektur CNN dirancang dengan beberapa lapisan konvolusi untuk menangkap hierarki fitur dari anomali berdurasi pendek pada lapisan awal sampai pola fluktuasi kompleks yang mungkin berlangsung berjam-jam atau berhari-hari pada lapisan yang lebih dalam. Desain ini secara inheren mengasumsikan bahwa prekursor seismik memiliki tekstur atau bentuk yang dapat dibedakan dari noise latar belakang atau variasi diurnal normal, yang dapat dipelajari oleh model. Pada pelatihan model dengan pendekatan supervised learning, model diajarkan untuk

membedakan antara dua kondisi seismic (segmen data yang berasosiasi dengan periode pra-gempa) dan non-seismik. Proses pelatihan ini memerlukan dataset yang cukup dan telah dilabeli secara cermat, agar setiap windowed segment memiliki label yang sesuai. Jantung dari proses pelatihan adalah optimasi hyperparameter yang bertujuan untuk menemukan konfigurasi model yang paling optimal untuk tugas klasifikasi. Algoritma optimisasi secara adaptif menyesuaikan laju pembelajaran (*learning rate*) untuk setiap parameter dalam model, menuju kondisi konvergen lebih cepat dan menghindari titik minimum lokal yang suboptimal dengan minimisasi fungsi kerugian (*loss function*). Selama ribuan iterasi, model secara bertahap menyesuaikan bobot internalnya untuk meminimalkan kesalahan prediksi, sehingga secara efektif mempelajari tanda-tanda subtil dalam citra data geomagnetik yang berkorelasi kuat dengan label seismic.

Model deep learning yang banyak digunakan mengolah data citra adalah Convolutional Neural Network. Secara umum Convolutional Neural Network terdiri dari pendeteksi fitur dan pengklasifikasi. Data set akan di ekstrak menjadi fitur-fitur secara konvolusi dalam kernel-kernel berukuran tertentu untuk dideteksi. Hasil deteksi fitur ini akan diklasifikasi sesuai dengan data labelnya melalui *fulled connected layer*.



Gambar 3.3. Diagram Arsitektur Convolutional Neural Network
(Rancangan, diolah)

Pada Gambar 3.3 disajikan Diagram Arsitektur Convolutional Neural Network rancangan awal penelitian ini. Proses pelatihan model estimasi akan melibatkan penggunaan dataset yang mencakup data historis mengenai gempabumi dan pengukuran medan magnet yang terkait. Model akan dilatih untuk mengenali

pola dalam data yang berkaitan dengan perubahan medan magnet dan menghubungkannya dengan arah datangnya gelombang seismik.

Tahap validasi dan evaluasi kinerja model untuk memastikan keandalan dan generalisasinya. Proses evaluasi akan dilakukan dengan menggunakan dataset pengujian yang belum pernah digunakan dalam pelatihan. Hal ini bertujuan untuk mengukur kemampuan model dalam menggeneralisasi pengetahuan yang diperoleh dari data pelatihan ke data baru (Goodfellow et al., 2016). Sebuah model data pelatihan yang berkinerja baik dan efektif tidak hanya menghafal data training tersebut (overfitting), kemampuan generalisasi model diukur secara objektif menggunakan set data pengujian (test dataset) yang sepenuhnya baru dan belum pernah dilihat oleh model selama fase pelatihan.

Evaluasi kinerja dilakukan dengan melibatkan serangkaian metrik komprehensif. Indikator precision mengukur keakuratan prediksi positif dan recall (sensitivitas) mengukur kelengkapan deteksi. Indikator *F1-score* menunjukkan keseimbangan harmonis antara precision dan recall. Metrik Matthews Correlation Coefficient (MCC), yang dianggap sebagai ukuran paling robust untuk klasifikasi biner dengan memperhitungkan kategori dalam matriks konfusi (true positives, true negatives, false positives, false negatives). Nilai MCC yang mendekati +1 menunjukkan kinerja prediksi yang mendekati sempurna, memberikan keyakinan bahwa model CNN mampu mendeteksi sinyal prekursor secara konsisten dan andal. Evaluasi model merupakan langkah penting dalam penelitian ini, karena memberikan gambaran mengenai kinerja model dalam memprediksi prekursor gempa bumi. Proses evaluasi akan dilakukan dengan menggunakan dataset pengujian yang belum pernah digunakan dalam pelatihan. Hal ini bertujuan untuk mengukur kemampuan model dalam menggeneralisasi pengetahuan yang diperoleh dari data pelatihan ke data baru (Goodfellow et al., 2016). Metrik *F1-score* ini akan memberikan gambaran yang komprehensif mengenai kinerja masing-masing model yang dikembangkan, baik dalam klasifikasi prekursor gempa bumi maupun dalam estimasi azimuth dan magnitudo (Sokolova & Lapalme, 2009).

Hasil evaluasi akan dibandingkan antara model klasifikasi, estimasi azimuth, dan estimasi magnitudo untuk menentukan model mana yang paling efektif dalam

memprediksi prekursor gempa bumi. Selain itu, analisis kesalahan juga akan dilakukan untuk mengidentifikasi pola kesalahan yang mungkin terjadi dan untuk memahami faktor-faktor yang mempengaruhi kinerja model. Dengan demikian, penelitian ini tidak hanya akan menghasilkan model yang akurat, tetapi juga memberikan wawasan yang lebih dalam mengenai proses yang terlibat dalam prediksi gempa bumi.

Akhirnya, hasil dari evaluasi model akan disusun dalam bentuk laporan yang mencakup analisis mendalam tentang temuan, kesimpulan, dan rekomendasi untuk penelitian lebih lanjut. Laporan ini diharapkan dapat memberikan kontribusi yang signifikan terhadap bidang penelitian gempa bumi dan pengembangan teknologi prediksi gempa bumi yang lebih akurat dan efektif.

3.4. Pembuatan Generator Data Augmentasi

Kelangkaan kejadian gempa bumi signifikan yang didahului oleh anomali geomagnetik yang terekam dengan jelas menjadi tantangan utama dalam melatih model deep learning seperti Convolutional Neural Network (CNN). Model pembelajaran *deep learning* membutuhkan data yang cukup banyak untuk mendapatkan hasil yang konsisten dan dapat melakukan generalisasi secara efektif. Dengan data yang cukup model mampu mengenali pola-pola prekursor yang subtil dan kompleks di tengah derau (*noise*) data yang tinggi. Kekurangan data yang memadai, model CNN sangat rentan terhadap overfitting, di mana model hanya menghafal contoh-contoh yang ada dalam set pelatihan dan gagal mengidentifikasi prekursor pada data baru yang belum pernah dilihat sebelumnya.

Data set untuk data pelatihan dan data pengujian merupakan data ULF magnet bumi yang sudah divalidasi sebagai prekursor gempa bumi di wilayah Indonesia dengan sampel data tahun 2018 – 2024. Mengingat keterbatasan dataset historis yang tersedia, tahapan ini dikembangkan generator data sintetis dengan augmentasi data. Teknik ini menghasilkan data buatan yang menyerupai sinyal prekursor geomagnetik berdasarkan parameter fisik dan pola-pola statistik yang telah diidentifikasi pada data riil. Data sintetis digabungkan dengan dataset asli untuk

memperkaya jumlah data pelatihan, sehingga meningkatkan kemampuan generalisasi model deteksi CNN.

Pembuatan generator data sintetis adalah solusi yang canggih untuk mengatasi keterbatasan model *neural network*. Dengan menganalisis secara mendalam parameter fisis, pola-pola statistik dari data prekursor riil yang telah divalidasi dan verifikasi, kita dapat membangun model dinamis generatif. Model ini tidak sekadar mereplikasi data yang ada, tetapi mampu menghasilkan sinyal-sinyal baru yang secara statistik dan fisis menyerupai karakteristik prekursor gempa bumi di wilayah Indonesia dan secara berkesinambungan menambah database prekursor dari waktu ke waktu. Dengan metode ini akan diperoleh model prekursor yang konsisten dengan akurasi tinggi yang tervalidasi.

Proses augmentasi merupakan proses menghasilkan data baru secara artifisial dari data yang ada, terutama untuk melatih model *machine learning* baru. Model *machine learning* membutuhkan set data yang besar dan beragam untuk pelatihan awal, tetapi mendapatkan set data dunia nyata yang cukup beragam menjadi tantangan tersendiri karena keterbatasan kejadian gempa bumi yang berhasil direkam oleh sensor. Proses augmentasi akan menggabungkan data riil dan data sintetis ini secara signifikan akan memperkaya keragaman dan volume set data pelatihan. Hasilnya adalah model deteksi CNN yang lebih kokoh (*robust*) dan memiliki kemampuan generalisasi yang jauh lebih unggul, sehingga meningkatkan akurasi dan keandalannya dalam mengidentifikasi sinyal-sinyal ULF sebagai prekursor gempa bumi di masa depan. Dengan berjalannya waktu, tahun demi tahun akan diproduksi data prekursor gempa bumi natural dari rekaman sensor dan data sintesis regenerative dengan augmentasi *machine learning*.

Salah satu tantangan paling fundamental dalam pengembangan model prediksi gempa berbasis *machine learning* adalah keterbatasan dan ketidakseimbangan dataset ULF geomagnetik yang berkorelasi dengan gempa bumi. Kejadian gempa signifikan dengan magnitudo di atas 6 secara statistik jarang terjadi, dibandingkan dengan data kondisi normal. Pada penelitian ini langkah ilmiah yang dilakukan untuk mengatasi kendala kritis ini, diterapkan teknik

augmentasi data historis yang sudah valid sebagai solusi strategis dalam penambahan volume data.

Pendekatan ini bukan sekadar memperbanyak data, melainkan menciptakan sampel-sampel data prekursor baru yang realistis secara artifisial, misalnya dengan menambahkan derau (noise) geofisika yang wajar, melakukan pergeseran waktu (time-shifting) pada sinyal, atau mengkombinasikan segmen data yang ada. Dengan memperkaya keragaman dataset secara cerdas, model akan dipaksa untuk mempelajari fitur-fitur esensial dari sebuah sinyal prekursor secara lebih tangguh, mengurangi risiko overfitting, dan pada akhirnya meningkatkan kapabilitas prediksi model bahkan dengan jumlah data historis kejadian gempa besar yang terbatas. Data sintetis hasil generasi dan augmentasi menjadi kebaharuan yang fundamental dalam penelitian ini.

3.5. Pengembangan Model CNN Fitur Self-Updating

Sebagai peningkatan kemampuan adaptasi model, CNN akan dikembangkan dengan mekanisme self-updating. Artinya, model akan secara berkala diperbarui (dengan retraining) menggunakan data gempa terbaru sebagai label, sehingga model dapat menyesuaikan diri dengan perubahan kondisi seismotektonik local. Pengembangan model CNN untuk deteksi prekursor gempa bumi harus berlandaskan bahwa sistem fisika bumi, khususnya kondisi seismotektonik suatu wilayah, bersifat dinamis dan terus berevolusi.

Proses-proses tektonik yang mengakumulasi dan melepaskan energi tidaklah stasioner. Karakteristik sinyal prekursor ULF geomagnetik yang kita amati hari ini mungkin akan mengalami pergeseran subtil di masa depan akibat perubahan pada lempeng tektonik, akumulasi stres, atau dinamika fluida di kerak bumi. Pemodelan prediktif yang statis, yang hanya dilatih sekali pada data historis, berisiko menjadi usang dan kehilangan akurasinya seiring berjalannya waktu. Di sinilah letak urgensi untuk merancang sebuah model yang cerdas dan mampu beradaptasi.

Langkah teknis model CNN dengan fitur *self-updating* diawali dengan perancangan arsitektur CNN dasar yang dilatih secara offline menggunakan data set historis dengan fitur spasio temporal yang relevan dari sinyal prekursor. Setelah model dasar ini mencapai kinerja yang memuaskan, diintegrasikan ke dalam sebuah

pipeline data streaming yang terhubung langsung dengan sensor lapangan. Mekanisme self-updating kemudian diimplementasikan menggunakan teknik online learning, di mana bobot model diperbarui secara inkremental setiap kali ada batch data baru yang masuk, seringkali memanfaatkan algoritma efisien seperti Stochastic Gradient Descent (SGD). Setelah model dasar ini mencapai kinerja yang memuaskan, diintegrasikan ke dalam sebuah pipeline sumber data streaming. Mekanisme self-updating kemudian diimplementasikan menggunakan teknik online learning, di mana bobot model diperbarui secara inkremental setiap kali ada batch data baru yang masuk, seringkali memanfaatkan algoritma efisien seperti SGD. Proses ini dilengkapi dengan feedback loop otomatis yang memvalidasi performa prediksi secara kontinu. Konsep ini mentransformasi model dari entitas statis menjadi sistem yang hidup dan berevolusi.

Proses ini memungkinkan bobot dan parameter internal jaringan CNN untuk terus-menerus menyesuaikan diri (fine-tuning), menyerap informasi dari pola-pola anomali terbaru yang mungkin muncul akibat perubahan kondisi geofisik lokal. Implementasi fitur self-updating ini secara fundamental akan meningkatkan kemampuan adaptasi dan relevansi jangka panjang dari sistem deteksi kita. Dengan terus belajar dari data-data termutakhir, model CNN tidak hanya mempertahankan, tetapi juga meningkatkan performa dan kemampuan generalisasinya terhadap kondisi seismotektonik yang terus berubah di wilayah Indonesia.

Pendekatan ini memastikan bahwa model tidak terjebak pada pengetahuan masa lalu, melainkan secara proaktif menyesuaikan diri dengan realitas geofisik saat ini. Pada akhirnya, tujuannya adalah untuk menciptakan sebuah sistem peringatan dini gempa bumi yang tidak hanya canggih, tetapi juga dinamis, adaptif, dan semakin andal dari waktu ke waktu.

3.6. Integrasi Data Multi-Parameter

Pada tahap ini dirancang framework untuk mengintegrasikan output model deteksi sinyal prekursor (hasil penelitian di tahun pertama) dengan data dari sensor lain, sehingga diperoleh informasi yang lebih lengkap mengenai aktivitas seismogenik. Data geomagnetik, seismik, ionosferik, dan atmosfer akan disinkronkan berdasarkan timestamp untuk membangun dataset multimodal yang

terstruktur. Selanjutnya integrasi dilakukan pada level fitur, dimana ekstraksi fitur dilakukan secara terpisah pada setiap jenis data sebelum digabungkan. Fitur-fitur yang memiliki korelasi tinggi dengan kejadian gempa akan dipilih dengan Principal Component Analysis (PCA).

Augmentasi data merupakan fase pengembangan sistem ini, sebuah kerangka kerja (*framework*) yang komprehensif dan terintegrasi secara sistematis dirancang. Tujuan utamanya adalah untuk memperoleh pemahaman yang jauh lebih lengkap dan mendalam mengenai berbagai aktivitas seismogenik yang mendahului gempa bumi. Kerangka kerja ini secara fundamental dirancang untuk melampaui keterbatasan analisis parameter tunggal dengan cara menggabungkan output dari model deteksi sinyal prekursor—yang telah dikembangkan pada penelitian tahun pertama—dengan aliran data heterogen yang berasal dari beragam jenis sensor lainnya.

Langkah awal yang krusial dalam metodologi ini adalah sinkronisasi masing-masing data terhadap waktu kejadiannya. Proses verifikasi awal oleh ahlinya untuk memperoleh validitas data, menjadi syarat mutlak sebelum metode integrasi multi parameter ini diterapkan. Berbagai jenis data, yang mencakup data geomagnetik, seismik, ionosferik, dan atmosfer, akan diselaraskan secara teliti berdasarkan penanda waktu (*timestamp*) yang presisi. Proses penyelarasan ini sangat vital untuk membangun sebuah dataset multimodal yang solid, terstruktur, dan koheren, yang menjadi fondasi utama untuk analisis terintegrasi yang akan dilakukan selanjutnya.

Proses integrasi selanjutnya dieksekusi pada level fitur, bukan pada level data mentah. Pilihan strategis ini memungkinkan dilakukannya proses ekstraksi fitur secara terpisah dan lebih mendalam untuk setiap jenis data. Dengan demikian, setiap modalitas (geomagnetik, seismik, dll.) dapat mengungkapkan informasi dan pola uniknya secara maksimal sebelum digabungkan. Setelah proses ekstraksi, kami memanfaatkan metode statistik canggih, Principal Component Analysis (PCA), untuk melakukan seleksi fitur. PCA secara efektif akan mengidentifikasi dan memilih fitur-fitur yang memiliki korelasi statistik paling tinggi terhadap kejadian

gempa, sekaligus berfungsi untuk mereduksi dimensi data dan menyaring noise atau informasi yang tidak relevan.

Semua fitur terpilih yang paling informatif dari berbagai sumber data tersebut kemudian digabungkan dan disusun ke dalam sebuah vektor fitur tunggal yang padat informasi. Vektor fitur yang kaya dan multi-aspek inilah yang akan menjadi masukan (input) utama untuk model prediksi gempa, sehingga diharapkan dapat meningkatkan akurasi dan keandalan prediksi secara signifikan.

Pendekatan yang diusulkan tersebut secara sadar bergerak melampaui keterbatasan analisis konvensional yang sering kali terisolasi pada satu parameter, menuju sebuah paradigma holistik yang mensintesis informasi dari berbagai domain geofisika dan atmosfer. Metodologi sistematis mulai dari sinkronisasi data presisi berbasis timestamp untuk menciptakan dataset multimodal yang koheren dan data strategis untuk melakukan integrasi pada level fitur, menunjukkan sebuah rancangan yang matang dan bertujuan. Pilihan untuk mengekstraksi fitur secara terpisah memastikan bahwa kekayaan informasi unik dari setiap aliran data tetap terjaga dan dapat dianalisis secara mendalam sebelum digabungkan.

3.7. Pengembangan Model Prediksi Parameter Gempa

Selain deteksi biner sinyal prekursor, model akan diperluas untuk mengestimasi parameter gempa bumi (magnitudo, lokasi dan waktu kejadian). Hal ini dilakukan dengan mengintegrasikan output dari model deteksi CNN dengan data seismik dan parameter pendukung lainnya melalui model tambahan seperti model regresi atau hybrid-model, sehingga prediksi yang dihasilkan lebih informatif dan aplikatif untuk sistem peringatan dini. Model estimasi azimuth untuk memperkirakan arah datangnya gelombang seismik berdasarkan data magnet bumi. Estimasi yang akurat mengenai azimuth penting untuk menentukan lokasi episentrum gempabumi. Dalam studi sebelumnya, penggunaan RNN untuk memprediksi azimuth telah menunjukkan akurasi yang tinggi, dengan rata-rata kesalahan estimasi kurang dari 5 derajat (Chen et al., 2020). Model estimasi magnitudo dikembangkan menggunakan teknik regresi berbasis deep learning untuk mencapai akurasi prediksi magnitudo hingga 85% (Wang et al., 2023). Model prediksi dikembangkan diuji dengan data validasi yang terpisah dan menggunakan

cross-validation untuk memastikan kestabilan kinerja. Pengujian dilakukan dengan membandingkan prediksi model dengan kejadian gempa yang terjadi menggunakan data historis gempa.

Pengembangan model prediksi parameter gempa bumi untuk memperluas kapabilitas model agar memberikan peringatan dini dan mampu mengestimasi parameter kunci gempa bumi yaitu magnitudo, lokasi episentrum, dan waktu kejadian. Model tersebut dilakukan integrasi output dari model deteksi berbasis CNN data seismik sebagai label dan parameter lainnya. Proses integrasi ini akan difasilitasi oleh model tambahan, seperti model regresi atau hybrid-model, untuk menghasilkan prediksi yang jauh lebih informatif dan aplikatif peringatan dini generasi berikutnya.

Secara spesifik, penentuan lokasi episentrum akan sangat bergantung pada model estimasi azimuth yang akurat, yang bertugas memperkirakan arah datangnya gelombang seismik primer berdasarkan anomali pada data magnet bumi. Estimasi azimuth yang presisi merupakan kunci utama untuk melokalisasi sumber gempa. Model estimasi magnitudo, kami akan menerapkan teknik regresi berbasis *deep learning* yang cerdas, menargetkan tingkat akurasi prediksi hingga 85%.

3.8. Pengembangan Generator Data Sintesis

Penelitian prekursor gempa bumi dengan data magnet bumi sebelumnya, penggunaan CNN untuk klasifikasi citra magnetik telah menunjukkan hasil yang menjanjikan, dengan akurasi mencapai 80% pada dataset tertentu (Zhang et al., 2021). Hasil tersebut dengan menggunakan data olahan dari sensor tanpa menambahkan data sintesis untuk proses estimasi dan ekstraksi fiturnya. Pengembangan generator data sintesis ini akan menambah jumlah data training yang akan memperbaiki algoritma CNN.

Teknik ini menghasilkan data buatan yang menyerupai sinyal prekursor seismogenik berdasarkan parameter fisik dan pola-pola statistik yang telah diidentifikasi pada data riil. Data sintetis digabungkan dengan dataset asli untuk memperkaya jumlah data pelatihan, sehingga meningkatkan kemampuan generalisasi model prediksi CNN. Metode generator data sintesis pada CNN digunakan untuk simulasi pada tahap selanjutnya dengan tujuan untuk

mengklasifikasikan data magnet bumi ke dalam kategori tertentu, kemudian membuat prediksi terjadi gempabumi atau tidak.

Model multi klasifikasi ini membuat estimasi azimuth dan magnitude gempa bumi. Estimasi azimuth untuk memperkirakan arah datangnya gelombang seismik berdasarkan data magnet bumi. Dalam studi sebelumnya, penggunaan RNN untuk memprediksi azimuth telah menunjukkan akurasi yang tinggi, dengan rata-rata kesalahan estimasi kurang dari 5 derajat (Chen et al., 2020). Model ini dilatih untuk mengenali pola data perubahan medan magnet yang terjadi sebelum gempabumi.

Model estimasi magnitudo dikembangkan untuk memperkirakan kekuatan gempabumi yang mungkin terjadi. Model ini akan dilatih menggunakan data historis anomali data magnet bumi dengan rasio Z/H yang sudah di Analisa sebelumnya dan di susun dalam dataset CNN. Penelitian sebelumnya menunjukkan bahwa model yang menggunakan teknik regresi berbasis deep learning dapat mencapai akurasi prediksi magnitudo hingga 85% (Wang et al., 2019).

Dengan memanfaatkan data training berupa anomali data magnet bumi yang diolah dengan rasio Z/H yang tervalidasi dan ditambah data sintesinya, diharapkan model ini dapat memberikan estimasi yang lebih akurat mengenai magnitudo gempabumi yang akan datang.

3.9. Pengembangan Model Prediksi Fitur Online Learning

Pada akhir penelitian dilakukan simulasi penerapan sistem prediksi secara online. Sistem prediksi gempa bumi diintegrasikan dalam platform online dengan streaming data. Umpan balik dari uji online akan digunakan untuk menyempurnakan model dan pipeline prediksi, yaitu model diperbarui secara online dari sensor. Teknik ini memungkinkan terjadinya proses adaptasi instan terhadap perubahan lingkungan seismik. Salah satu cara yang digunakan adalah dengan Stochastic Gradient Descent (SGD). Hasil tahap ini digunakan dalam penelitian selanjutnya tentang implementasi sistem prediksi gempabumi secara real time.

Mekanisme inti dari pendekatan ini adalah kemampuan model untuk beradaptasi secara instan. Setiap umpan balik dari pengujian online akan dimanfaatkan untuk menyempurnakan baik model maupun keseluruhan alur

(*pipeline*) prediksi. Artinya, bobot dan parameter model akan diperbarui secara online seiring masuknya data baru. Teknik ini akan diimplementasikan menggunakan metode efisien seperti SGD, memungkinkan terjadinya proses adaptasi instan terhadap setiap perubahan halus dalam kondisi lingkungan seismik. Kemampuan ini memastikan model kami tetap relevan dan akurat dalam menghadapi dinamika kebumihan yang terus berubah. Pengembangan fitur online learning ini bukanlah tujuan akhir, melainkan sebuah jembatan strategis yang sangat penting. Seluruh metodologi, arsitektur, dan hasil yang diperoleh dari tahap ini akan menjadi fondasi utama bagi penelitian selanjutnya, implementasi sistem prediksi gempa bumi secara real-time. Dengan model yang mampu belajar dan beradaptasi secara mandiri, untuk mewujudkan sistem peringatan dini yang tidak hanya cepat dan akurat, tetapi juga cerdas dan tangguh dalam jangka panjang.

3.10. Jadwal Pelaksanaan Penelitian

Penelitian ini ditargetkan akan selesai dalam kurun waktu 3(tiga) tahun dan akan dimulai awal tahun 2025. Dalam rangka menjaga ketepatan waktu penelitian dan pelaksanaan penelitian yang terstruktur, disusun jadwal Pelaksanaan Penelitian. Tahapan penelitian dan waktu pelaksanaan penelitian ini disajikan dalam tabel 3.1.

Tabel 3.1 Jadwal Pelaksanaan Penelitian

Tahun	No	Uraian Kegiatan	Bulan											
			1	2	3	4	5	6	7	8	9	10	11	12
1	1	Studi literatur magnet bumi												
	2	Studi literatur model precursor gempa bumi												
	3	Studi literatur machine learning												
	4	Penyusunan proposal kualifikasi												
	5	Preprocessing data magnet bumi												

DAFTAR PUSTAKA

- Ahadi, S., Puspito, N. T., Ibrahim, G., & Saroso, S. (2014a). Determination of the onset time in polarization power ratio Z/H for precursor of Sumatra earthquake. *AIP Conference Proceedings*, 75–78. <https://doi.org/10.1063/1.4897108>
- Ahadi, S., Puspito, N. T., Ibrahim, G., & Saroso, S. (2014b). *Determination of the onset time in polarization power ratio Z/H for precursor of Sumatra earthquake*. 75–78. <https://doi.org/10.1063/1.4897108>
- Ahyar, A. S., & Sunardi, B. (2017). KORELASI POLARISASI MAGNET Z/H UNTUK IDENTIFIKASI PREKURSOR GEMPA DI SEKITAR PELABUHAN RATU. *Spektra: Jurnal Fisika dan Aplikasinya*, 2(3), 179–186. <https://doi.org/10.21009/spektra.023.03>
- Akyol, A. A., Arikan, O., & Arikan, F. (2020). A Machine Learning-Based Detection of Earthquake Precursors Using Ionospheric Data. *Radio Science*, 55(11), Article 11. <https://doi.org/10.1029/2019RS006931>
- Antonopoulou, A., Balasis, G., Papadimitriou, C., Boutsis, A. Z., Rontogiannis, A., Koutroumbas, K., Daglis, I. A., & Giannakis, O. (2022). Convolutional Neural Networks for Automated ULF Wave Classification in Swarm Time Series. *Atmosphere*, 13(9), Article 9. <https://doi.org/10.3390/atmos13091488>
- Badan Meteorologi, Klimatologi, dan Geofisika. (2024). *Katalog Gempabumi Merusak Tahun 1821-2023* (Cetakan pertama). Pusat Gempa Bumi dan Tsunami Kedeputian Bidang Geofisika, BMKG. https://cdn.bmkg.go.id/Web/FA_Katalog-Gempabumi-Merusak-1821-2023.pdf
- Bao, Z., Zhao, J., Huang, P., Yong, S., & Wang, X. (2021). A Deep Learning-Based Electromagnetic Signal for Earthquake Magnitude Prediction. *Sensors (Basel, Switzerland)*, 21(13), 4434. <https://doi.org/10.3390/s21134434>
- Cárdenas, J., Denis, C., Mousannif, H., Camerlynck, C., & Florsch, N. (2022). Magnetic anomalies characterization: Deep learning and explainability. *Computers & Geosciences*, 169, 105227. <https://doi.org/10.1016/j.cageo.2022.105227>

- Chen, W., Yang, L., Zha, B., Zhang, M., & Chen, Y. (2020). Deep learning reservoir porosity prediction based on multilayer long short-term memory network. *GEOPHYSICS*, 85(4), WA213–WA225. <https://doi.org/10.1190/geo2019-0261.1>
- Chi, P. J., Russell, C. T., Le, G., Hughes, W. J., & Singer, H. J. (1996). A synoptic study of Pc 3, 4 waves using the Air Force Geophysics Laboratory magnetometer array. *Journal of Geophysical Research: Space Physics*, 101(A6), 13215–13224. <https://doi.org/10.1029/96JA00139>
- Currie, J. L., & Waters, C. L. (2014). On the use of geomagnetic indices and ULF waves for earthquake precursor signatures. *Journal of Geophysical Research: Space Physics*, 119(2), 992–1003. <https://doi.org/10.1002/2013JA019530>
- Draz, M. U., Shah, M., Jamjareegulgarn, P., Shahzad, R., Hasan, A. M., & Ghamry, N. A. (2023). Deep Machine Learning Based Possible Atmospheric and Ionospheric Precursors of the 2021 Mw 7.1 Japan Earthquake. *Remote Sensing*, 15(7), Article 7. <https://doi.org/10.3390/rs15071904>
- Febriani, F., Ahadi, S., Anggono, T., Syuhada, Dewi, C. N., & Prasetyo, A. D. (2021). Applying Wavelet Analysis to Assess the Ultra Low Frequency (ULF) Geomagnetic Anomalies prior to the M6.1 Banten Earthquake (2018). *IOP Conference Series: Earth and Environmental Science*, 789(1), 012064. <https://doi.org/10.1088/1755-1315/789/1/012064>
- Feng, L., Qu, R., Ji, Y., Zhu, W., Zhu, Y., Feng, Z., Fan, W., Guan, Y., & Xie, C. (2022). Multistationary Geomagnetic Vertical Intensity Polarization Anomalies for Predicting $M \geq 6$ Earthquakes in Qinghai, China. *Applied Sciences*, 12(17), 8888. <https://doi.org/10.3390/app12178888>
- Fenoglio, M. A., Johnston, M. J. S., & Byerlee, J. D. (1995). Magnetic and electric fields associated with changes in high pore pressure in fault zones: Application to the Loma Prieta ULF emissions. *Journal of Geophysical Research: Solid Earth*, 100(B7), 12951–12958. <https://doi.org/10.1029/95JB00076>
- Freund, F. T., Takeuchi, A., & Lau, B. W. S. (2006). Electric currents streaming out of stressed igneous rocks – A step towards understanding pre-

- earthquake low frequency EM emissions. *Physics and Chemistry of the Earth, Parts A/B/C*, 31(4–9), 389–396. <https://doi.org/10.1016/j.pce.2006.02.027>
- Hamidi, M., Ahadi, S., Friska, V., & Marzuki, M. (2024a). Investigating ultra-low frequency emissions and total electron content anomalies as earthquake precursors in Sumatra (2019–2020). *Kuwait Journal of Science*, 51(2), 100196. <https://doi.org/10.1016/j.kjs.2024.100196>
- Hamidi, M., Ahadi, S., Friska, V., & Marzuki, M. (2024b). Investigating ultra-low frequency emissions and total electron content anomalies as earthquake precursors in Sumatra (2019–2020). *Kuwait Journal of Science*, 51(2), 100196. <https://doi.org/10.1016/j.kjs.2024.100196>
- Hao, G., Guo, J., Zhang, W., Chen, Y., & Yuen, D. A. (2022). High-precision chaotic radial basis function neural network model: Data forecasting for the Earth electromagnetic signal before a strong earthquake. *Geoscience Frontiers*, 13(1), 101315. <https://doi.org/10.1016/j.gsf.2021.101315>
- Hattori, K. (2004). ULF Geomagnetic Changes Associated with Large Earthquakes. *Terrestrial, Atmospheric and Oceanic Sciences*, 15, 329–360. [https://doi.org/10.3319/TAO.2004.15.3.329\(EP\)](https://doi.org/10.3319/TAO.2004.15.3.329(EP))
- Hattori, K., Serita, A., Yoshino, C., Hayakawa, M., & Isezaki, N. (2006). Singular spectral analysis and principal component analysis for signal discrimination of ULF geomagnetic data associated with 2000 Izu Island Earthquake Swarm. *Physics and Chemistry of the Earth*, 31, 281–291. <https://doi.org/10.1016/j.pce.2006.02.034>
- Hayakawa, M. (2016). *Earthquake prediction with electromagnetic phenomena*. 020002. <https://doi.org/10.1063/1.4941201>
- Hayakawa, M., Hattori, K., & Kenji, O. (2007). Monitoring of ULF (Ultra-Low-Frequency) Geomagnetic Variations Associated with Earthquakes. *Sensors*, 7. <https://doi.org/10.3390/s7071108>
- Hayakawa, M., Itoh, T., Hattori, K., & Yumoto, K. (2000). ULF electromagnetic precursors for an earthquake at Biak, Indonesia on February 17, 1996. *Geophysical Research Letters*, 27(10), 1531–1534. <https://doi.org/10.1029/1999GL005432>

- Hayakawa, M., Izutsu, J., Schekotov, A., Yang, S.-S., Solovieva, M., & Budilova, E. (2021). Lithosphere–Atmosphere–Ionosphere Coupling Effects Based on Multiparameter Precursor Observations for February–March 2021 Earthquakes (M~7) in the Offshore of Tohoku Area of Japan. *Geosciences*, 11(11), 481. <https://doi.org/10.3390/geosciences11110481>
- Ian Goodfellow and Yoshua Bengio and Aaron Courville. (2016). *Deep Learning*. <https://www.deeplearningbook.org/>
- Karakelian, D., Klemperer, S., Fraser, A., & Beroza, G. (2000). A Transportable System for Monitoring Ultra Low Frequency Electromagnetic Signals Associated with Earthquakes. *Seismological Research Letters*, 71. <https://doi.org/10.1785/gssrl.71.4.423>
- Kavianpour, P., Kavianpour, M., Jahani, E., & Ramezani, A. (2023). A CNN-BiLSTM model with attention mechanism for earthquake prediction. *Journal of Supercomputing*, 79(17), Article 17. <https://doi.org/10.1007/s11227-023-05369-y>
- Kopytenko, Y., Ismagilov, V., Hayakawa, M., Smirnova, N., Troyan, V., & Peterson, T. (2001). Investigation of the ULFelectromagnetic phenomena related to earthquakes: Contemporary achievements and the perspectives. *Annals of Geophysics*, 44(2), Article 2. <https://doi.org/10.4401/ag-3599>
- Kurniawan, W., Daryono, Kerta, I., Pranata, B., & Winugroho, T. (2021). Monitoring and analysis of seismic data during the 2018 sunda strait tsunami. *E3S Web of Conferences*, 331, 07006. <https://doi.org/10.1051/e3sconf/202133107006>
- Kushwah, V., Singh, V., Singh, B., & Hayakawa, M. (2005). Ultra low frequency (ULF) magnetic field anomalies observed at Agra and their relation to moderate seismic activity in Indian region. *Journal of Atmospheric and Solar-Terrestrial Physics*, 67, 992–1001. <https://doi.org/10.1016/j.jastp.2005.04.005>
- Marzuki, M., Hamidi, M., Ahadi, S., Putra, A., Afdal, A., Harmadi, H., Karnawati, D., Suprihatin, H. S., Syirojudin, M., & Marsyam, I. (2022a). ULF geomagnetic anomaly associated with the Sumatra-Pagai Islands

- earthquake swarm during 2020. *Contributions to Geophysics and Geodesy*, 52(2). <https://doi.org/10.31577/congeo.2022.52.2.2>
- Marzuki, M., Hamidi, M., Ahadi, S., Putra, A., Afdal, A., Harmadi, H., Karnawati, D., Suprihatin, H. S., Syirojudin, M., & Marsyam, I. (2022b). ULF geomagnetic anomaly associated with the Sumatra-Pagai Islands earthquake swarm during 2020. *Contributions to Geophysics and Geodesy*, 52(2), Article 2. <https://doi.org/10.31577/congeo.2022.52.2.2>
- Merzer, M., & Klemperer, S. L. (1997). Modeling Low-frequency Magnetic-field Precursors to the Loma Prieta Earthquake with a Precursory Increase in Fault-zone Conductivity. *Pure and Applied Geophysics*, 150(2), 217–248. <https://doi.org/10.1007/s000240050074>
- Miao, C., Dong, Q., Hao, M., Wang, C., & Cao, J. (2021). Magnetic anomaly detection based on fast convergence wavelet artificial neural network in the aeromagnetic field. *Measurement*, 176, 109097. <https://doi.org/10.1016/j.measurement.2021.109097>
- Mignan, A., & Broccardo, M. (2020). Neural network applications in earthquake prediction (1994-2019): Meta-analytic and statistical insights on their limitations. *Seismological Research Letters*, 91(4), Article 4. <https://doi.org/10.1785/02202000021>
- Molchanov, O. A., & Hayakawa, M. (1998). On the generation mechanism of ULF seismogenic electromagnetic emissions. *Physics of the Earth and Planetary Interiors*, 105(3), 201–210. [https://doi.org/10.1016/S0031-9201\(97\)00091-5](https://doi.org/10.1016/S0031-9201(97)00091-5)
- Ouyang, X. Y., Parrot, M., & Bortnik, J. (2020). ULF Wave Activity Observed in the Nighttime Ionosphere Above and Some Hours Before Strong Earthquakes. *Journal of Geophysical Research: Space Physics*, 125(9), e2020JA028396. <https://doi.org/10.1029/2020JA028396>
- Pappoe, J. A., Yoshikawa, A., Kandil, A., & Mahrous, A. (2023). A machine learning approach combined with wavelet analysis for automatic detection of Pc5 geomagnetic pulsations observed at geostationary orbits. *Advances in Space Research*. <https://doi.org/10.1016/j.asr.2023.11.001>

- Pappoe, J. A., Yoshikawa, A., Kandil, A., & Mahrous, A. (2024). A machine learning approach combined with wavelet analysis for automatic detection of Pc5 geomagnetic pulsations observed at geostationary orbits. *Advances in Space Research*, 74(12), 6277–6291. <https://doi.org/10.1016/j.asr.2023.11.001>
- Petrescu, L., & Moldovan, I.-A. (2022a). Prospective Neural Network Model for Seismic Precursory Signal Detection in Geomagnetic Field Records. *Machine Learning and Knowledge Extraction*, 4(4), 912–923. <https://doi.org/10.3390/make4040046>
- Petrescu, L., & Moldovan, I.-A. (2022b). Prospective Neural Network Model for Seismic Precursory Signal Detection in Geomagnetic Field Records. *Machine Learning and Knowledge Extraction*, 4(4), 912–923. <https://doi.org/10.3390/make4040046>
- Pulinets, S., & Ouzounov, D. (2018). *The Possibility of Earthquake Forecasting: Learning from nature*. IOP Publishing. <https://doi.org/10.1088/978-0-7503-1248-6>
- Pusat Studi Gempa Nasional (Indonesia) & Pusat Penelitian dan Pengembangan Perumahan dan Permukiman (Indonesia) (Eds.). (2017). *Peta sumber dan bahaya gempa Indonesia tahun 2017* (Cetakan pertama). Pusat Penelitian dan Pengembangan Perumahan dan Permukiman, Badan Penelitian dan Pengembangan, Kementerian Pekerjaan Umum.
- Rabie, E., Hafez, A. G., Saad, O. M., El-Sayed, A.-H. M., Abdelrahman, K., & Al-Otaibi, N. (2021). Geomagnetic micro-pulsation automatic detection via deep leaning approach guided with discrete wavelet transform. *Journal of King Saud University - Science*, 33(1), 101263. <https://doi.org/10.1016/j.jksus.2020.101263>
- Stănică, D. A., & Stănică, D. (2021). Possible Correlations between the ULF Geomagnetic Signature and Mw6.4 Coastal Earthquake, Albania, on 26 November 2019. *Entropy*, 23(2), 233. <https://doi.org/10.3390/e23020233>
- Sumawan, Widjiantoro, B. L., & Indriawati, K. (2024). Application of the ULF Geomagnetic Anomaly Method as a Precursor to Earthquakes in East Nusa

Tenggara. *International Conference on Interdisciplinary Physics (ICIPs) in Conjunction with Bond21*.

- Syed Zafar, S. N. A., Umar, R., Hazmin, S. N., Jusoh, M. H., Yoshikawa, A., Abe, S., Uozumi, T., Afandi, N. Z. M., & Mahiddin, N. A. (2024). Modelling of ULF Pc4—Pc5 Pulsations with solar winds and geomagnetic storm for ULF earthquake precursor. *Advances in Space Research*, 73(3), 1814–1830. <https://doi.org/10.1016/j.asr.2023.10.036>
- Wang, Y., Ma, W., Zhao, B., Yue, C., Zhu, P., Yu, C., & Yao, L. (2023). Responses to the Preparation of the 2021 M7.4 Madoi Earthquake in the Lithosphere–Atmosphere–Ionosphere System. *Atmosphere*, 14(8), 1315. <https://doi.org/10.3390/atmos14081315>
- Warden, S., MacLean, L., Lemon, J., & Schneider, D. (2020). Statistical Analysis of Pre-earthquake Electromagnetic Anomalies in the ULF Range. *Journal of Geophysical Research: Space Physics*, 125(10), e2020JA027955. <https://doi.org/10.1029/2020JA027955>
- Wu, Z., Xia, J., Tan, B., Wang, B., Zhao, Q., & He, S. (2024). Detection and characterization of geomagnetic anomaly waveforms. *Journal of Asian Earth Sciences*, 259, 105837. <https://doi.org/10.1016/j.jseaes.2023.105837>
- Xiang, C., Li, M., Ma, Z., Teng, C., Li, Z., & Shao, Z. (2022). Ultra-Low Frequency Electromagnetic Emissions Registered during the 21 May 2021 Yangbi M S 6.4 Earthquake in China. *Natural Science*, 14, 1–12. <https://doi.org/10.4236/ns.2022.141001>
- Yang, B.-Y., Li, Z., Huang, J.-P., Yang, X.-M., Yin, H.-C., Li, Z.-Y., Lu, H.-X., Li, W.-J., Shen, X.-H., Zeren, Z., Tan, Q., & Zhou, N. (2023). EMD based statistical analysis of nighttime pre-earthquake ULF electric field disturbances observed by CSES. *Frontiers in Astronomy and Space Sciences*, 9. <https://doi.org/10.3389/fspas.2022.1077592>
- Yumoto, K. (1986a). Generation and propagation mechanisms of low-latitude magnetic pulsations—A review. *Journal of Geophysics Zeitschrift Geophysik*, 60, 79–105.

- Yumoto, K. (1986b). Generation mechanism of Pc3 magnetic pulsations at very low latitudes. *Planetary and Space Science*, 34(12), 1329–1334. [https://doi.org/10.1016/0032-0633\(86\)90069-3](https://doi.org/10.1016/0032-0633(86)90069-3)
- Yusof, K. A., Abdullah, M., Hamid, N. S. A., Ahadi, S., & Yoshikawa, A. (2021a). Correlations between Earthquake Properties and Characteristics of Possible ULF Geomagnetic Precursor over Multiple Earthquakes. *Universe*, 7(1), 20. <https://doi.org/10.3390/universe7010020>
- Yusof, K. A., Abdullah, M., Hamid, N. S. A., Ahadi, S., & Yoshikawa, A. (2021b). Correlations between Earthquake Properties and Characteristics of Possible ULF Geomagnetic Precursor over Multiple Earthquakes. *Universe*, 7(1), Article 1. <https://doi.org/10.3390/universe7010020>